



TRƯỜNG ĐẠI HỌC QUY NHƠN

TIỂU LUẬN HỌC PHẦN
HỌC SÂU VÀ ỨNG DỤNG

ỨNG DỤNG MẠNG GRU DỰ BÁO
NỒNG ĐỘ PM_{2.5}
TẠI THÀNH PHỐ QUY NHƠN

Trình độ đào tạo:	Thạc sĩ
Học viên thực hiện:	Nguyễn Hồ Bảo Thiên
Lớp:	Khoa học dữ liệu K28B
Giảng viên hướng dẫn:	TS. Lê Xuân Vinh

Mục lục

Mở đầu	3
1 Cơ sở lý thuyết	5
1.1 Bài toán dự báo chuỗi thời gian bằng học sâu	5
1.2 Recurrent Neural Network (RNN)	5
1.3 Long Short-Term Memory (LSTM)	7
1.4 Gated Recurrent Unit (GRU)	8
2 Ứng dụng dự báo nồng độ PM2.5	13
2.1 Mô tả dữ liệu	13
2.2 Phân tích khám phá dữ liệu (EDA)	14
2.3 Tiền xử lý dữ liệu	20
2.4 Xây dựng mô hình	22
2.5 Đánh giá mô hình: Walk-forward trên dữ liệu mới	24
2.6 Kết luận	26
Tài liệu tham khảo	27

Danh sách hình vẽ

1.1	Kiến trúc mạng nơ-ron hồi quy (RNN)	6
1.2	Kiến trúc LSTM cell (nguồn: Zhang và cộng sự, <i>Dive into Deep Learning</i> , Chương 10)	8
1.3	Kiến trúc GRU: tính toán Reset gate, Update gate và Trạng thái ẩn ứng viên (nguồn: Zhang và cộng sự, <i>Dive into Deep Learning</i> , Chương 9)	9
1.4	Recursive GRU: giá trị dự báo ở bước trước được đưa ngược trở lại làm đầu vào cho bước sau	11
1.5	Direct GRU: một Encoder duy nhất, output rộng ra thẳng cả H bước cùng lúc, không đệ quy	12
2.1	Ma trận tương quan Pearson giữa các chỉ số chất lượng không khí	14
2.2	Chuỗi thời gian nồng độ PM2.5 (2022–2026)	15
2.3	Phân phối PM2.5: Histogram và ước lượng mật độ (KDE)	15
2.4	PM2.5 và đường trung bình trượt (Moving Average) 7, 30 và 90 ngày . . .	16
2.5	ACF và PACF của PM2.5 theo giờ (168 lag = 1 tuần)	16
2.6	Phân rã chuỗi thời gian PM2.5 theo chu kỳ năm (Trend + Seasonal + Residual)	17
2.7	Seasonal Subseries Plot: PM2.5 theo từng tháng (gộp tất cả các năm) . . .	18
2.8	Phân phối PM2.5 theo từng năm (Violin Plot)	19
2.9	PM2.5 trung bình ngày so với ngưỡng khuyến nghị WHO và QCVN Việt Nam	19
2.10	Kiến trúc hybrid: EWMA ước lượng Trend, GRU học Residual, cộng lại thành PM2.5 dự báo	20
2.11	Learning curve — GRU Residual (hidden_size=32, horizon=7 ngày): toàn bộ quá trình (trái) và phóng to từ epoch 3 (phải), đường chấm xám đánh dấu epoch tốt nhất	23
2.12	PM2.5: Thực tế và Dự báo walk-forward trên tập Test (đường chấm xám đánh dấu ranh giới giữa các khoảng thời gian)	25
2.13	Residual (Thực tế – Dự báo) trên tập Test, tổng hợp cả 4 khoảng thời gian walk-forward	25

Danh sách bảng

2.1	Thống kê mô tả các biến định lượng	14
2.2	Phân chia Train / Validate / Test (dữ liệu theo ngày)	22
2.3	Kết quả Grid Search siêu tham số (val_loss trung bình trên 38 fold Validate, sắp xếp tăng dần)	23
2.4	Hiệu năng mô hình hybrid trên tập Test theo từng khoảng thời gian walk-forward	24

Mở đầu

Ô nhiễm không khí đang trở thành một trong những vấn đề môi trường đáng quan tâm tại các khu vực đô thị, trong đó bụi mịn PM2.5 là một trong những tác nhân gây ảnh hưởng nghiêm trọng đến sức khỏe con người. PM2.5 là các hạt vật chất có đường kính khí động học không vượt quá $2.5, \mu m$. Với kích thước rất nhỏ, các hạt này có khả năng xâm nhập sâu vào hệ hô hấp, thậm chí đi vào hệ tuần hoàn, từ đó làm gia tăng nguy cơ mắc các bệnh liên quan đến đường hô hấp và tim mạch. Vì vậy, việc dự báo sớm nồng độ PM2.5, đặc biệt trong khoảng thời gian ngắn, có ý nghĩa quan trọng đối với công tác cảnh báo chất lượng không khí, hỗ trợ cộng đồng chủ động bảo vệ sức khỏe và góp phần nâng cao hiệu quả quản lý môi trường đô thị.

Trong tiểu luận này, bài toán được xây dựng dưới dạng **dự báo chuỗi thời gian (time series forecasting)**, với mục tiêu dự báo nồng độ PM2.5 trong một khoảng thời gian tới, dựa trên lịch sử quan trắc trong một khoảng thời gian trước đó. Dữ liệu đầu vào được tổ chức dưới dạng chuỗi thời gian đa biến, bao gồm nồng độ PM2.5, các chỉ số chất lượng không khí có liên quan và các đặc trưng về thời gian. Mô hình học sâu được lựa chọn là **GRU (Gated Recurrent Unit)**, một biến thể của mạng nơ-ron hồi quy (Recurrent Neural Network – RNN) được thiết kế nhằm học các mối quan hệ phụ thuộc theo thời gian và khắc phục một số hạn chế của RNN truyền thống khi xử lý các chuỗi có phụ thuộc dài hạn.

Bộ dữ liệu sử dụng trong tiểu luận được thu thập từ **Open-Meteo Air Quality API** tại tọa độ $13.800003^{\circ}N$, $109.20001^{\circ}E$, tương ứng với khu vực thành phố Quy Nhơn, ở độ cao khoảng **9 m so với mực nước biển**. Dữ liệu được ghi nhận theo tần suất hàng giờ, liên tục từ 2022-08-04 07:00 đến 2026-07-26 23:00, với tổng cộng **34.865 quan sát**. Khoảng thời gian quan trắc kéo dài gần bốn năm cung cấp cơ sở dữ liệu đủ lớn để khảo sát các đặc trưng theo thời gian của PM2.5 cũng như huấn luyện và đánh giá mô hình dự báo.

Trên cơ sở bài toán và mục tiêu nghiên cứu đã đặt ra, tiểu luận được triển khai theo một quy trình gồm các nội dung chính sau:

- Thu thập, kiểm tra và làm sạch dữ liệu;
- Phân tích khám phá dữ liệu (EDA) theo đặc trưng của chuỗi thời gian, tập trung vào xu hướng, tính chu kỳ và cấu trúc tự tương quan;
- Tiền xử lý dữ liệu và xây dựng đặc trưng, bao gồm mã hóa các đặc trưng thời gian có tính chu kỳ, chuẩn hóa dữ liệu và xây dựng các cửa sổ quan sát bằng phương pháp sliding window;
- Xây dựng mô hình GRU và tiến hành tinh chỉnh các siêu tham số phù hợp;
- Đánh giá khả năng dự báo của mô hình trên tập kiểm tra, đồng thời kiểm chứng trên một tập dữ liệu hoàn toàn mới được thu thập ở giai đoạn sau nhằm đánh giá

khả năng tổng quát hóa trong điều kiện *out-of-sample* thực tế.

Trên cơ sở đó, báo cáo sẽ trình bày lần lượt quá trình chuẩn bị dữ liệu, phân tích đặc trưng chuỗi thời gian, xây dựng và huấn luyện mô hình, đánh giá kết quả dự báo, đồng thời thảo luận những kết quả đạt được và các hạn chế còn tồn tại của mô hình.

Chương 1

Cơ sở lý thuyết

1.1 Bài toán dự báo chuỗi thời gian bằng học sâu

Khác với các bài toán học có giám sát thông thường, dữ liệu chuỗi thời gian có tính tuần tự: giá trị tại thời điểm t có quan hệ phụ thuộc với các giá trị trong quá khứ. Cách tiếp cận phổ biến để chuyển bài toán dự báo chuỗi thời gian thành bài toán học có giám sát là kỹ thuật **sliding window**: với một cửa sổ quan sát độ dài w (window size) và một khoảng dự báo h (horizon), ta xây dựng cặp dữ liệu

$$X_t = (x_{t-w+1}, x_{t-w+2}, \dots, x_t) \longrightarrow y_t$$

trong đó $x_i \in \mathbb{R}^n$ là vector n đặc trưng tại thời điểm i , còn y_t là giá trị của biến mục tiêu (biến cần dự báo) tại bước thời gian $t + h$ trong tương lai.

Phần tiếp theo trình bày cơ sở lý thuyết của các kiến trúc mạng nơ-ron hồi quy theo trình tự **RNN** $\rightarrow$ **LSTM** $\rightarrow$ **GRU**. Trước hết, RNN truyền thống được giới thiệu cùng với cơ chế xử lý dữ liệu tuần tự và những hạn chế trong việc học các phụ thuộc dài hạn. Tiếp đó, LSTM được trình bày như một kiến trúc cải tiến nhằm khắc phục các hạn chế này thông qua cơ chế bộ nhớ và các cổng điều khiển. Cuối cùng, GRU — kiến trúc được sử dụng trong tiểu luận — được giới thiệu như một biến thể đơn giản hơn của LSTM, với số lượng cổng và tham số ít hơn nhưng vẫn có khả năng mô hình hóa các mối quan hệ phụ thuộc theo thời gian.

1.2 Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) là một kiến trúc mạng nơ-ron được xây dựng để xử lý dữ liệu có tính tuần tự, chẳng hạn như chuỗi thời gian, văn bản hoặc tín hiệu. Khác với mạng nơ-ron truyền thẳng (*feedforward neural network*), trong đó mỗi đầu vào được xử lý độc lập, RNN duy trì một **trạng thái ẩn** (*hidden state*) để truyền thông tin từ các bước thời gian trước sang bước hiện tại. Nhờ đó, kết quả xử lý tại một thời điểm không chỉ phụ thuộc vào quan sát hiện tại mà còn chịu ảnh hưởng bởi thông tin đã xuất hiện trước đó trong chuỗi.


Tại thời điểm t , RNN nhận đầu vào x_t cùng với trạng thái ẩn của bước trước h_{t-1} để tính trạng thái ẩn mới h_t theo công thức:

$$h_t = \tanh(W_h x_t + U_h h_{t-1} + b_h), \quad (1.1)$$

trong đó $x_t \in \mathbb{R}^n$ là vector đặc trưng tại thời điểm t ; h_{t-1} và h_t lần lượt là trạng thái ẩn tại thời điểm $t-1$ và t ; W_h là ma trận trọng số liên kết đầu vào với trạng thái ẩn; U_h là ma trận trọng số của kết nối hồi quy giữa hai trạng thái ẩn liên tiếp; b_h là vector bias; và $\tanh(\cdot)$ là hàm kích hoạt phi tuyến. Trạng thái ban đầu h_0 thường được khởi tạo bằng vector không hoặc được xác định theo cấu hình của mô hình.

Thông qua quan hệ hồi quy trên, trạng thái h_t phụ thuộc không chỉ vào x_t mà còn gián tiếp phụ thuộc vào các quan sát trước đó thông qua h_{t-1} . Chẳng hạn, h_{t-1} lại được tính từ x_{t-1} và h_{t-2} , và quá trình này tiếp tục ngược về các bước thời gian trước. Vì vậy, về mặt lý thuyết, trạng thái h_t có khả năng tổng hợp thông tin từ chuỗi các quan sát $x_1, x_2, \dots, x_t$ và đóng vai trò như một dạng bộ nhớ của mạng tại thời điểm t .

Một đặc điểm quan trọng của RNN là cùng một bộ tham số (W_h, U_h, b_h) được sử dụng tại tất cả các bước thời gian. Việc chia sẻ tham số này cho phép mạng xử lý các chuỗi có độ dài khác nhau mà không cần xây dựng một tập tham số riêng cho từng vị trí trong chuỗi. Khi biểu diễn dưới dạng khai triển theo thời gian (*unrolled*), một RNN có thể được xem như một chuỗi các tế bào mạng có cùng cấu trúc và cùng trọng số, trong đó trạng thái ẩn được truyền tuần tự từ bước này sang bước kế tiếp.



Hình 1.1: Kiến trúc mạng nơ-ron hồi quy (RNN)

Hình 1.1 minh họa hai cách biểu diễn tương đương của một RNN. Ở dạng cuộn, kết nối hồi quy thể hiện việc trạng thái của tế bào mạng được truyền trở lại để sử dụng tại bước thời gian tiếp theo. Khi khai triển theo thời gian, cùng một tế bào A được biểu diễn tại nhiều thời điểm liên tiếp. Tại mỗi bước, tế bào nhận đầu vào x_t và trạng thái ẩn h_{t-1} từ bước trước để tạo ra trạng thái mới h_t , sau đó h_t tiếp tục được truyền sang bước kế tiếp. Các tế bào trong hình không phải là những mạng độc lập mà cùng chia sẻ một bộ tham số.

Mặc dù cơ chế hồi quy cho phép RNN về lý thuyết khai thác thông tin từ các quan sát trong quá khứ, RNN truyền thống gặp khó khăn khi cần học các mối quan hệ phụ thuộc cách xa nhau trong chuỗi. Nguyên nhân chủ yếu xuất hiện trong quá trình huấn luyện bằng **lan truyền ngược qua thời gian** (*Backpropagation Through Time – BPTT*). Theo quy tắc dây chuyền, ảnh hưởng của một trạng thái ở thời điểm $t-k$ đến trạng thái tại thời điểm t được xác định thông qua tích của nhiều đạo hàm liên tiếp:

$$\frac{\partial h_t}{\partial h_{t-k}} = \prod_{j=t-k+1}^t \frac{\partial h_j}{\partial h_{j-1}}. \quad (1.2)$$

Khi chuỗi dài, việc liên tục nhân các đạo hàm này có thể khiến gradient giảm rất nhanh về gần 0, được gọi là hiện tượng **vanishing gradient**. Khi đó, thông tin từ những

bước thời gian ở xa hầu như không còn đóng góp đáng kể vào quá trình cập nhật trọng số, khiến RNN khó học được các phụ thuộc dài hạn. Ngược lại, gradient cũng có thể tăng lên rất lớn qua nhiều bước, gây ra hiện tượng **exploding gradient**, làm quá trình huấn luyện trở nên không ổn định.

Những hạn chế trên, đặc biệt là vấn đề vanishing gradient khi xử lý các phụ thuộc dài hạn, là một trong những động lực chính dẫn đến sự phát triển của các kiến trúc RNN có cơ chế cổng như **Long Short-Term Memory (LSTM)** và sau đó là **Gated Recurrent Unit (GRU)**.

1.3 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM), được đề xuất bởi Hochreiter và Schmidhuber (1997), là một kiến trúc mở rộng của RNN nhằm cải thiện khả năng học các quan hệ phụ thuộc dài hạn trong dữ liệu chuỗi. So với RNN truyền thống, điểm khác biệt quan trọng của LSTM là việc bổ sung một **trạng thái cell** (*cell state*) ký hiệu là C_t . Trạng thái này đóng vai trò như một kênh lưu trữ thông tin xuyên suốt theo trục thời gian, cho phép thông tin quan trọng được duy trì qua nhiều bước liên tiếp với ít biến đổi hơn. Nhờ đó, quá trình lan truyền gradient ngược qua thời gian trở nên ổn định hơn, từ đó làm giảm ảnh hưởng của hiện tượng vanishing gradient vốn là hạn chế điển hình của RNN nguyên bản.

Bên cạnh trạng thái cell, LSTM còn sử dụng các **cổng điều khiển** (*gates*) để kiểm soát luồng thông tin đi vào, được giữ lại hay được đưa ra khỏi bộ nhớ. Mỗi cổng được xây dựng bằng hàm sigmoid, cho đầu ra trong khoảng $[0, 1]$, nhờ đó có thể được hiểu như một cơ chế “đóng – mở” để điều tiết mức độ truyền thông tin. Tại thời điểm t , LSTM nhận đầu vào hiện tại x_t và trạng thái ẩn của bước trước h_{t-1} để tính toán các đại lượng trung gian như sau.

Trước hết, **cổng quên** (*forget gate*) xác định mức độ thông tin từ trạng thái cell trước đó C_{t-1} cần được giữ lại:

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad (1.3)$$

Trong đó, nếu một phần tử của f_t có giá trị gần 1 thì thông tin tương ứng trong C_{t-1} gần như được giữ nguyên; ngược lại, nếu giá trị gần 0 thì thông tin đó sẽ bị loại bỏ phần lớn.

Tiếp theo, **cổng vào** (*input gate*) quyết định mức độ thông tin mới sẽ được ghi vào trạng thái cell:

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad (1.4)$$

Song song với đó, mạng tính một **trạng thái cell ứng viên** thể hiện nội dung mới có thể được bổ sung vào bộ nhớ:

$$\tilde{C}_t = \tanh(W_C x_t + U_C h_{t-1} + b_C) \quad (1.5)$$

Từ hai thành phần trên, trạng thái cell tại thời điểm t được cập nhật bằng cách kết hợp thông tin cũ cần giữ lại với thông tin mới cần bổ sung:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (1.6)$$


Trong công thức này, ký hiệu $\odot$ biểu diễn phép nhân theo từng phần tử. Thành phần $f_t \odot C_{t-1}$ cho biết phần thông tin cũ còn được duy trì, trong khi $i_t \odot \tilde{C}_t$ biểu diễn phần thông tin mới được thêm vào bộ nhớ.

Sau khi trạng thái cell mới C_t được hình thành, **cổng ra** (*output gate*) sẽ quyết định phần nào của thông tin trong cell state được sử dụng để tạo ra trạng thái ẩn tại thời điểm hiện tại:

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad (1.7)$$

$$h_t = o_t \odot \tanh(C_t) \quad (1.8)$$

Như vậy, trạng thái ẩn h_t không phải là toàn bộ nội dung của C_t , mà là phần thông tin đã được “lọc” qua cổng ra. Trạng thái này vừa đóng vai trò đầu ra của ô nhớ tại thời điểm t , vừa được truyền sang bước thời gian tiếp theo cùng với trạng thái cell C_t .



Hình 1.2: Kiến trúc LSTM cell (nguồn: Zhang và cộng sự, *Dive into Deep Learning*, Chương 10)

Hình 1.2 minh họa luồng thông tin trong một cell LSTM: đường ngang phía trên (cell state $\mathbf{C}_t$) chỉ tương tác với phần còn lại của mạng qua hai phép toán đơn giản (nhân theo phần tử với $\mathbf{F}_t$, cộng với $\mathbf{I}_t \odot \tilde{\mathbf{C}}_t$) — gần như không đi qua hàm phi tuyến nào, giúp gradient lan truyền ngược tốt hơn. Bốn cổng $\mathbf{F}_t, \mathbf{I}_t, \tilde{\mathbf{C}}_t, \mathbf{O}_t$ đều nhận đầu vào là $\mathbf{H}_{t-1}$ nối với $\mathbf{X}_t$; trạng thái ẩn $\mathbf{H}_t$ (không vẽ trong hình, xem công thức ở trên) được tính riêng bằng cách đưa $\mathbf{C}_t$ qua $\tanh(\cdot)$ rồi nhân theo phần tử với cổng ra $\mathbf{O}_t$. Với ba cổng độc lập và một cell state riêng biệt, LSTM có nhiều tham số hơn RNN nhưng giải quyết hiệu quả vấn đề vanishing gradient, trở thành kiến trúc RNN có cổng được sử dụng rộng rãi nhất trong nhiều năm.

1.4 Gated Recurrent Unit (GRU)

Gated Recurrent Unit (GRU), được đề xuất bởi Cho và cộng sự (2014), là một kiến trúc mạng nơ-ron hồi quy có cổng được xây dựng nhằm cải thiện khả năng học các phụ thuộc dài hạn của RNN truyền thống. Tương tự LSTM, GRU sử dụng các cổng điều khiển để

điều tiết luồng thông tin qua thời gian, nhưng có cấu trúc gọn hơn do không duy trì trạng thái ô nhớ C_t riêng biệt và chỉ sử dụng hai cổng chính: **cổng đặt lại** (*reset gate*) và **cổng cập nhật** (*update gate*).

Tại thời điểm t , với đầu vào x_t và trạng thái ẩn trước đó h_{t-1} , cổng đặt lại được xác định bởi:

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r), \quad (1.9)$$

trong đó r_t kiểm soát mức độ thông tin từ h_{t-1} được sử dụng khi xây dựng trạng thái ứng viên. Khi r_t có giá trị gần 0, ảnh hưởng của thông tin quá khứ tương ứng được giảm bớt; ngược lại, giá trị gần 1 cho phép thông tin đó được giữ lại nhiều hơn.

Cổng cập nhật được tính theo:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z), \quad (1.10)$$

và có nhiệm vụ điều tiết tỷ lệ giữa việc duy trì trạng thái ẩn trước đó và tiếp nhận thông tin mới.


Dựa trên cổng đặt lại, trạng thái ẩn ứng viên được xác định bởi:

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h), \quad (1.11)$$

trong đó $\odot$ biểu diễn phép nhân theo từng phần tử. Trạng thái ẩn tại thời điểm t sau đó được cập nhật theo:

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t. \quad (1.12)$$

Theo quy ước trên, khi z_t tiến gần 1, trạng thái trước đó h_{t-1} được giữ lại nhiều hơn; ngược lại, khi z_t tiến gần 0, trạng thái mới chủ yếu được xác định bởi trạng thái ứng viên $\tilde{h}_t$. Cơ chế này cho phép GRU duy trì thông tin quan trọng qua nhiều bước thời gian, qua đó hỗ trợ việc học các phụ thuộc dài hạn trong dữ liệu tuần tự.



Hình 1.3: Kiến trúc GRU: tính toán Reset gate, Update gate và Trạng thái ẩn ứng viên (nguồn: Zhang và cộng sự, *Dive into Deep Learning*, Chương 9)

Hình 1.3 minh họa bước tính Reset gate $\mathbf{R}_t$, Update gate $\mathbf{Z}_t$ và trạng thái ẩn ứng viên $\tilde{\mathbf{H}}_t$: khác với LSTM, GRU không có đường cell state riêng — $\mathbf{H}_{t-1}$ được "sao chép" thành hai nhánh, một đi thẳng vào hai cổng $\mathbf{R}_t, \mathbf{Z}_t$ (cùng $\mathbf{X}_t$), một được nhân theo phần tử với $\mathbf{R}_t$ trước khi cùng $\mathbf{X}_t$ tạo thành trạng thái ứng viên $\tilde{\mathbf{H}}_t$ qua $\tanh(\cdot)$. Trạng thái ẩn cuối cùng $\mathbf{H}_t$ (không vẽ trong hình, xem công thức ở trên) chỉ là bước nội suy tuyến tính đơn

giữa $\mathbf{H}_{t-1}$ và $\tilde{\mathbf{H}}_t$ theo hệ số $\mathbf{Z}_t$, không cần thêm phép biến đổi phi tuyến nào. Khi $z_t \rightarrow 1$, trạng thái ẩn gần như được giữ nguyên qua bước thời gian — cơ chế then chốt giúp GRU giảm thiểu vanishing gradient tương tự cell state của LSTM; khi $z_t \rightarrow 0$, trạng thái được thay gần như hoàn toàn bằng trạng thái ứng viên mới.

So với LSTM, việc sử dụng một trạng thái ẩn duy nhất và hai cổng điều khiển giúp GRU có cấu trúc gọn hơn và thường có ít tham số hơn, trong khi vẫn duy trì khả năng mô hình hóa các phụ thuộc dài hạn tốt hơn RNN truyền thống.

Với bài toán dự báo hồi quy (không phải phân loại) tại một horizon h cố định, cho trước ($h \geq 1$ là số bước thời gian cần dự báo trước, được chọn trước khi huấn luyện), đầu ra cuối cùng của mô hình là trạng thái ẩn tại bước thời gian cuối của cửa sổ đầu vào, đưa qua một lớp fully-connected tuyến tính để cho ra giá trị dự báo của biến mục tiêu tại bước $t + h$:

$$\hat{y}_{t+h} = W_{fc} h_w + b_{fc}, \quad (1.13)$$

với h_w là trạng thái ẩn tại bước cuối cùng (w) của cửa sổ đầu vào. Horizon h ở đây là một **siêu tham số kiến trúc**: mỗi model chỉ được huấn luyện để dự báo đúng một giá trị h duy nhất — muốn đổi sang horizon khác phải huấn luyện lại từ đầu.

Trong thực tế, nhiều bài toán cần dự báo **đồng thời nhiều horizon khác nhau** (chẳng hạn cả $1, 2, \dots, H$ bước tới cùng lúc), thay vì chỉ một h duy nhất như kiến trúc cơ sở ở trên. Hai chiến lược phổ biến để mở rộng một model một-horizon sang dự báo H bước tương lai được trình bày dưới đây.


Recursive GRU

Một cách tiếp cận đơn giản để thực hiện dự báo nhiều bước tương lai mà không cần huấn luyện một mô hình mới là sử dụng lặp lại mô hình GRU dự báo một bước ($h = 1$) đã được huấn luyện trước. Chiến lược này được gọi là **recursive forecasting**. Ý tưởng cốt lõi là sau khi mô hình dự báo giá trị tại thời điểm $t + 1$, giá trị dự báo đó sẽ được đưa ngược trở lại chuỗi đầu vào để tiếp tục dự báo cho thời điểm $t + 2$, và quá trình này được lặp lại cho đến khi đạt horizon mong muốn H .

Cụ thể, tại bước dự báo thứ k ($k = 1, \dots, H$), mô hình tạo ra dự báo:

$$\hat{y}_{t+k} = f_{\theta}(\tilde{x}_{t-w+k}, \dots, \tilde{x}_{t-1+k}), \quad (1.14)$$

trong đó f_{θ} là mô hình GRU dự báo một bước đã được huấn luyện, còn $\tilde{x}_i$ là vector đặc trưng tại thời điểm i . Nếu $i \leq t$, ta có $\tilde{x}_i = x_i$, tức là sử dụng dữ liệu quan trắc thực tế. Nếu $i > t$, thành phần mục tiêu trong $\tilde{x}_i$ được thay thế bằng chính giá trị dự báo trước đó $\hat{y}_i$. Đối với các đặc trưng ngoại sinh chưa có giá trị trong tương lai, một lựa chọn thực hành phổ biến là sử dụng giả định *persistence*, tức giữ nguyên giá trị cuối cùng đã biết. Riêng các đặc trưng thời gian có tính xác định, chẳng hạn như giờ trong ngày hoặc ngày trong tuần được mã hóa tuần hoàn, có thể được tính trực tiếp cho các thời điểm tương lai.



Hình 1.4: Recursive GRU: giá trị dự báo ở bước trước được đưa ngược trở lại làm đầu vào cho bước sau

Hình 1.4 minh họa cơ chế recursive qua ba bước đầu tiên. Ở Bước 1, cửa sổ đầu vào hoàn toàn gồm dữ liệu thực tế và mô hình tạo ra dự báo đầu tiên. Sang Bước 2, giá trị vừa dự báo được đưa vào cửa sổ đầu vào thay cho quan sát cũ nhất đã bị loại ra do cửa sổ trượt. Đến Bước 3, cửa sổ đầu vào đã chứa hai giá trị dự báo từ các bước trước. Như vậy, khi số bước dự báo tăng lên, số lượng giá trị dự báo được đưa ngược vào đầu vào cũng tăng dần, trong khi tỷ lệ dữ liệu thực tế trong cửa sổ giảm xuống.


Ưu điểm của chiến lược này là tận dụng trực tiếp mô hình dự báo một bước đã có sẵn mà không cần huấn luyện một mô hình riêng cho từng horizon. Tuy nhiên, hạn chế chính là hiện tượng **tích lũy sai số** (*error compounding*): sai số ở các bước dự báo đầu sẽ tiếp tục lan sang các bước sau do các giá trị dự báo được sử dụng làm đầu vào cho chính mô hình. Vì vậy, horizon dự báo càng xa thì độ tin cậy của kết quả thường càng giảm. Bên cạnh đó, việc giả định persistence đối với các đặc trưng ngoại sinh cũng có thể làm phát sinh thêm sai lệch nếu các đặc trưng này biến động đáng kể trong giai đoạn dự báo.

Direct GRU (Vector Output)

Chiến lược thứ hai giải quyết trực tiếp vấn đề dồn sai số của Recursive: thay vì tái sử dụng model horizon=1, **huấn luyện một model mới** dự đoán **toàn bộ H bước tương lai cùng lúc** trong một lần forward pass duy nhất.

Kiến trúc Encoder GRU được giữ nguyên như đã trình bày ở trên (đọc cửa sổ w giờ lịch sử, nén thành trạng thái ẩn cuối h_w), chỉ thay đổi duy nhất lớp fully-connected: thay vì Linear(hidden, 1) chỉ ra một số, dùng Linear(hidden, H) để ra thẳng H giá trị cùng lúc:

$$[\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+H}]^T = W_{fc} h_w + b_{fc}, \quad W_{fc} \in \mathbb{R}^{H \times \text{hidden}} \quad (1.15)$$



Hình 1.5: Direct GRU: một Encoder duy nhất, output rộng ra thẳng cả H bước cùng lúc, không đệ quy

Hình 1.5 cho thấy điểm khác biệt cốt lõi so với Recursive: cửa sổ input **luôn là dữ liệu thật 100%** — không có bước dự đoán nào bị đưa ngược lại làm input cho bước khác. Toàn bộ H dự đoán đều được tính **độc lập với nhau**, xuất phát từ cùng một ngữ cảnh h_w duy nhất.

Ưu điểm: vì không có cơ chế đệ quy, Direct GRU **không bị dồn sai số** qua các bước horizon — sai số ở bước dự đoán xa không phụ thuộc vào sai số ở bước gần.

Nhược điểm: model phải học đồng thời H mục tiêu khác nhau trong cùng một mạng (đa nhiệm), có thể đánh đổi đôi chút độ chính xác ở bước dự đoán gần nhất ($h = 1$) so với một model được huấn luyện chuyên biệt chỉ cho horizon=1 duy nhất; đồng thời cần huấn luyện lại từ đầu, không tái sử dụng được model horizon=1 sẵn có như Recursive.

Chương 2

Ứng dụng dự báo nồng độ PM2.5

2.1 Mô tả dữ liệu

Bộ dữ liệu gốc (`raw_data.csv`) được tải trực tiếp từ Open-Meteo Air Quality API, trải dài từ năm 2016 nhưng phần lớn giai đoạn đầu (2016 – giữa 2022) không có dữ liệu (toàn bộ giá trị NaN) do trạm quan trắc/API chưa cung cấp dữ liệu ở giai đoạn đó. Sau bước làm sạch (loại bỏ các hàng toàn NaN và các cột chứa NaN — trong đó `carbon_dioxide` và `methane` bị loại hoàn toàn vì chỉ có dữ liệu một phần thời gian), bộ dữ liệu sạch (`cleaned_data.csv`) còn lại **34.865 dòng** $\times$ **15 cột**, liên tục theo từng giờ từ 2022-08-04 07:00:00 đến 2026-07-26 23:00:00, không còn giá trị thiếu.

Các biến trong bộ dữ liệu sau khi chuẩn hóa tên cột:

- **PM10**: Nồng độ bụi mịn đường kính $\leq 10 \mu\text{m}$ ($\mu\text{g}/\text{m}^3$)
- **PM2.5**: Nồng độ bụi mịn đường kính $\leq 2.5 \mu\text{m}$ ($\mu\text{g}/\text{m}^3$) — *biến mục tiêu*
- **Carbon Monoxide (CO)**: Khí carbon monoxide ($\mu\text{g}/\text{m}^3$)
- **Nitrogen Dioxide (NO₂)**: Khí nitơ đioxit ($\mu\text{g}/\text{m}^3$)
- **Sulphur Dioxide (SO₂)**: Khí lưu huỳnh đioxit ($\mu\text{g}/\text{m}^3$)
- **Ozone (O₃)**: Khí ozone tầng mặt đất ($\mu\text{g}/\text{m}^3$)
- **Aerosol Optical Depth (AOD)**: Độ dày quang học sol khí, phản ánh mức độ khí quyển bị che khuất bởi hạt lơ lửng (không đơn vị)
- **Dust**: Nồng độ bụi ($\mu\text{g}/\text{m}^3$)
- **UV Index, UV Index Clear Sky**: Chỉ số tia UV thực tế và giả định trời quang mây (không đơn vị)
- **day, month, year, hour**: Các thành phần thời gian tách từ cột `time`

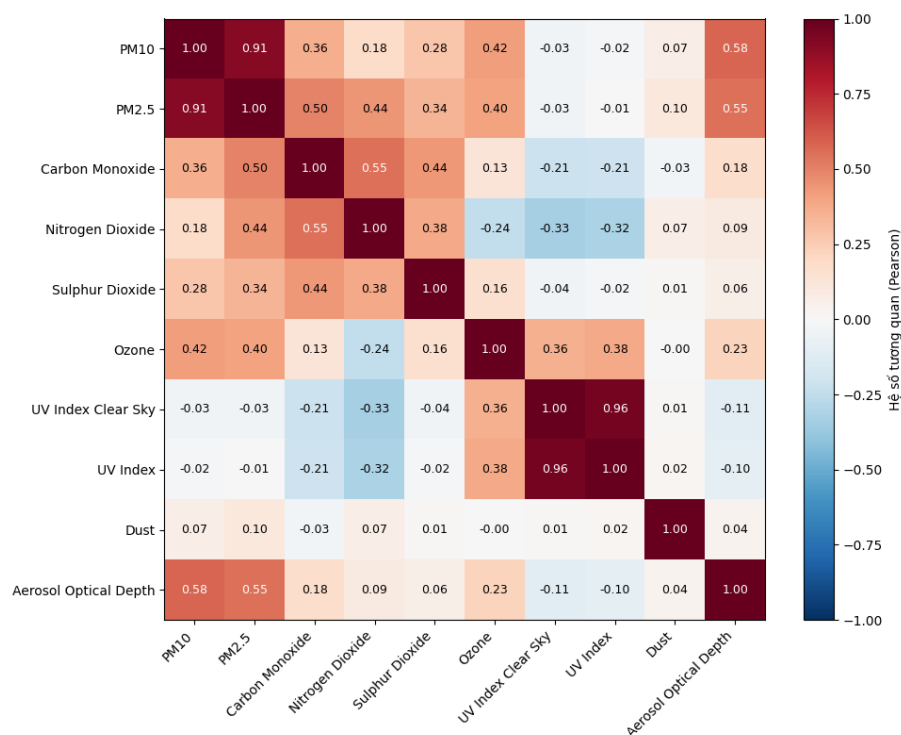
Bảng 2.1: Thống kê mô tả các biến định lượng

Biến	Đơn vị	Mean	Std	Min	Median	Max
PM10	$\mu\text{g}/\text{m}^3$	19.76	9.91	0.40	18.20	97.80
PM2.5	$\mu\text{g}/\text{m}^3$	13.73	7.06	0.30	12.50	71.50
Carbon Monoxide	$\mu\text{g}/\text{m}^3$	249.38	109.28	59.00	226.00	1185.00
Nitrogen Dioxide	$\mu\text{g}/\text{m}^3$	3.05	2.59	0.00	2.30	29.30
Sulphur Dioxide	$\mu\text{g}/\text{m}^3$	2.23	1.37	0.10	1.90	13.50
Ozone	$\mu\text{g}/\text{m}^3$	81.58	30.30	4.00	79.00	259.00
Aerosol Optical Depth	—	0.25	0.16	0.02	0.21	2.37
Dust	$\mu\text{g}/\text{m}^3$	0.42	1.45	0.00	0.00	37.00
UV Index	—	2.01	3.21	0.00	0.00	13.65
UV Index Clear Sky	—	2.53	3.84	0.00	0.00	14.10

Ba biến cuối (*Dust*, *UV Index*, *UV Index Clear Sky*) có trung vị bằng 0, cho thấy phân phối lệch phải rất mạnh với phần lớn giá trị bằng 0 — dấu hiệu cho thấy các biến này có thể ít mang thông tin hữu ích cho việc dự báo PM2.5, sẽ được kiểm chứng qua phân tích tương quan ở phần tiếp theo.

2.2 Phân tích khám phá dữ liệu (EDA)


Tương quan giữa các chỉ số chất lượng không khí




Hình 2.1: Ma trận tương quan Pearson giữa các chỉ số chất lượng không khí

Hình 2.1 cho thấy PM10 và PM2.5 có tương quan rất cao ($r = 0.91$) — phù hợp với thực tế vì PM2.5 là tập con của PM10. PM2.5 cũng có tương quan trung bình với Carbon Monoxide ($r = 0.50$), Nitrogen Dioxide ($r = 0.44$) và Aerosol Optical Depth ($r = 0.55$) — các chỉ số phần lớn liên quan đến hoạt động đốt cháy (giao thông, công nghiệp). Ngược lại, Dust ($r = 0.10$) và UV Index/UV Index Clear Sky ($r \approx -0.01$ đến -0.03) gần như không tương quan với PM2.5 — nhất quán với nhận xét về phân phối lệch ở trên.

Xu hướng và phân phối theo thời gian




Hình 2.2: Chuỗi thời gian nồng độ PM2.5 (2022–2026)



Hình 2.3: Phân phối PM2.5: Histogram và ước lượng mật độ (KDE)

Chuỗi PM2.5 (Hình 2.2) dao động chủ yếu trong khoảng $5\text{--}30\text{ }\mu\text{g}/\text{m}^3$, với các đợt tăng đột biến ngắn hạn (lên đến $\sim 70\text{ }\mu\text{g}/\text{m}^3$) và biểu hiện lặp lại theo mùa khá rõ. Phân phối PM2.5 (Hình 2.3) lệch phải, với giá trị trung vị (12.5) thấp hơn giá trị trung bình (13.73) — phù hợp với đặc điểm dữ liệu môi trường, nơi các sự kiện ô nhiễm cao là thiểu số nhưng có biên độ lớn.


Xu hướng theo Moving Average



Hình 2.4: PM2.5 và đường trung bình trượt (Moving Average) 7, 30 và 90 ngày

Hình 2.4 cho thấy các đường trung bình trượt 30 ngày và 90 ngày dao động lặp lại theo chu kỳ hàng năm — tăng vào giai đoạn đầu năm (khoảng tháng 1–4) và giảm dần về giữa năm — chứ không trôi dạt theo một hướng cố định qua các năm 2022–2026. Chuỗi giá trị thực tế (đường xám) dao động rất mạnh quanh các đường trung bình trượt, phản ánh nhiều đợt tăng đột biến ngắn hạn xen kẽ nền chu kỳ mùa; đặc điểm "không trôi dạt, chỉ dao động quanh một nền tương đối ổn định" này sẽ được thấy lại rõ hơn ở thành phần Trend khi phân rã chuỗi thời gian ngay sau đây.

Tính chu kỳ (Seasonality)



Hình 2.5: ACF và PACF của PM2.5 theo giờ (168 lag = 1 tuần)

Biểu đồ ACF (Hình 2.5) thể hiện các đỉnh lặp lại rõ rệt tại lag 24, 48, 72, 96... giờ — xác nhận **chu kỳ ngày (24 giờ)** là chu kỳ chi phối hành vi ngắn hạn của PM2.5, phù

hợp với quy luật sinh hoạt/giao thông đô thị (giờ cao điểm) lặp lại mỗi ngày. Đây là một trong những căn cứ cho quyết định gộp dữ liệu về mức trung bình ngày trước khi đưa vào mô hình (Mục 2.3), vì chu kỳ trong ngày không còn là yếu tố cần mô hình hóa trực tiếp ở granularity ngày.



Hình 2.6: Phân rã chuỗi thời gian PM2.5 theo chu kỳ năm (Trend + Seasonal + Residual)

Hình 2.6 trình bày kết quả phân rã cổ điển (classical decomposition, period= 365 ngày) áp dụng trên chuỗi PM2.5 trung bình ngày, tách thành bốn thành phần theo thứ tự từ trên xuống: giá trị thực tế (Observed), Trend, Seasonal và Residual.

Panel Observed lặp lại chính chuỗi đã thấy ở Hình 2.2, dao động phổ biến trong khoảng $5\text{--}25\text{ }\mu\text{g}/\text{m}^3$ và xen kẽ những đợt tăng vọt lên đến $35\text{--}40\text{ }\mu\text{g}/\text{m}^3$ vào một vài thời điểm (đầu năm 2023, đầu năm 2025, giữa năm 2026) — các cực trị này rơi đúng vào giai đoạn đầu năm mà đường trung bình trượt ở Hình 2.4 đã chỉ ra là cao điểm ô nhiễm hàng năm.


Thành phần Trend là một đường cong trơn, biến thiên rất chậm và chỉ trong biên độ hẹp $12\text{--}14.7\text{ }\mu\text{g}/\text{m}^3$: giảm dần từ khoảng 14.1 (giữa năm 2022) xuống đáy ≈ 11.9 (cuối năm 2023), sau đó tăng trở lại lên đỉnh ≈ 14.7 (đầu năm 2025), rồi lại giảm về ≈ 13.1 (cuối năm 2025) trước khi hồi phục nhẹ về cuối chuỗi quan sát. Đường Trend không tăng hay giảm đơn điệu mà chỉ dao động lên xuống quanh một nền chung khoảng $13\text{ }\mu\text{g}/\text{m}^3$ — cho thấy PM2.5 tại khu vực khảo sát không có dấu hiệu ô nhiễm ngày càng nghiêm trọng (hay cải thiện) rõ rệt qua các năm, mà chỉ trải qua những đợt lên/xuống chậm, biên độ nhỏ, nằm ngoài phạm vi chu kỳ năm và chưa đủ cơ sở để coi là một xu hướng dài hạn thật sự.

Ngược lại, thành phần Seasonal dao động trong khoảng -8 đến $+13$ và lặp lại đều

đạt theo từng năm: đạt đỉnh dương (khoảng +10 đến +13) vào giai đoạn tháng 1–4, rồi xuống đáy âm (khoảng –5 đến –8) vào giai đoạn giữa năm (tháng 6–9) — hoàn toàn nhất quán với quy luật "tăng đầu năm, giảm giữa năm" đã quan sát được ở Hình 2.4 và sẽ còn thấy lại ở Seasonal Subseries Plot (Hình 2.7) ngay sau đây. Đáng chú ý, biên độ dao động của thành phần Seasonal (xấp xỉ ± 13) lớn hơn nhiều so với biên độ của Trend (chưa đến 3 đơn vị) — khẳng định tính chu kỳ theo năm mới là yếu tố chi phối chính hành vi dài hạn của PM2.5, chứ không phải một xu hướng trôi dạt.

Cuối cùng, thành phần Residual dao động khá đều quanh mốc 0, phần lớn nằm trong khoảng ± 10 , nhưng thỉnh thoảng xuất hiện những đỉnh nhọn vượt 15–20 $\mu\text{g}/\text{m}^3$ (rõ nhất ở đầu năm 2023 và giữa năm 2025) trùng với các đợt tăng đột biến đã thấy ở panel Observed. Đây là phần biến động không được giải thích bởi Trend hay Seasonal, phản ánh các sự kiện ô nhiễm mang tính tức thời (điều kiện thời tiết bất lợi, hoạt động đốt theo mùa vụ...) — đúng là loại dao động ngắn hạn, khó đoán trước bằng thống kê cổ điển mà thành phần GRU trong kiến trúc hybrid ở Mục 2.3 được thiết kế để đảm nhiệm.


Biến động PM2.5 theo mùa trong năm



Hình 2.7: Seasonal Subseries Plot: PM2.5 theo từng tháng (gộp tất cả các năm)

Hình 2.7 cho thấy PM2.5 đạt đỉnh vào các tháng 1–4 (cao nhất ở tháng 4, trung bình $\approx 20 \mu\text{g}/\text{m}^3$), giảm dần xuống mức thấp nhất vào các tháng 7–10 (trung bình $\approx 10\text{--}12 \mu\text{g}/\text{m}^3$), rồi tăng nhẹ trở lại vào tháng 11–12. Kiểu biến động này phù hợp với đặc trưng khí hậu khu vực Nam Trung Bộ: các tháng đầu năm (gió mùa Đông Bắc, ít mưa) khiến bụi mịn tích tụ nhiều hơn, trong khi mùa mưa (tháng 7–10) giúp rửa trôi các hạt lơ lửng, làm giảm nồng độ PM2.5.


Phân phối PM2.5 theo từng năm



Hình 2.8: Phân phối PM2.5 theo từng năm (Violin Plot)

Hình 2.8 cho thấy giá trị trung vị/trung bình PM2.5 tương đối ổn định quanh 11–14 $\mu\text{g}/\text{m}^3$ trong giai đoạn 2022–2025, nhưng giá trị cực đại (đuôi phân phối) có xu hướng tăng dần qua từng năm — từ khoảng 44 $\mu\text{g}/\text{m}^3$ (2022) lên hơn 70 $\mu\text{g}/\text{m}^3$ (2025–2026) — cho thấy dù mức nền không đổi nhiều nhưng tần suất/cường độ các đợt ô nhiễm đỉnh điểm có dấu hiệu gia tăng. Riêng năm 2026 (dữ liệu mới tính đến tháng 7) có phân phối lệch cao hơn hẳn (trung vị ≈ 14.5) so với các năm trước; tuy nhiên cần lưu ý đây là năm chưa có đủ dữ liệu cả năm, nên tỷ trọng các tháng đầu năm — vốn có PM2.5 cao hơn theo Hình 2.7 — chiếm phần lớn có thể ảnh hưởng đến so sánh này.

Ngưỡng an toàn theo chuẩn WHO và QCVN Việt Nam



Hình 2.9: PM2.5 trung bình ngày so với ngưỡng khuyến nghị WHO và QCVN Việt Nam


Trong tổng số 1.453 ngày có dữ liệu, có **510 ngày (35.1%)** có nồng độ PM2.5 trung bình 24h vượt ngưỡng khuyến nghị của WHO Air Quality Guideline 2021 (15 $\mu\text{g}/\text{m}^3$) — cho thấy hơn một phần ba số ngày trong giai đoạn quan sát không đạt chuẩn an toàn theo khuyến nghị quốc tế. Ngược lại, **không có ngày nào (0.0%)** vượt ngưỡng QCVN 05:2013/BTNMT của Việt Nam (50 $\mu\text{g}/\text{m}^3$) (Hình 2.9) — phản ánh khoảng cách đáng kể giữa quy chuẩn hiện hành trong nước và chuẩn khuyến nghị siết chặt hơn của WHO.

2.3 Tiền xử lý dữ liệu

Trong quá trình thử nghiệm, một mô hình Direct GRU dự báo trực tiếp trên nồng độ PM2.5 tuyệt đối cho thấy hạn chế rõ rệt khi kiểm chứng trên dữ liệu mới: nồng độ PM2.5 thực tế trong giai đoạn đó suy giảm đáng kể so với nền mà mô hình đã học được từ dữ liệu huấn luyện — một dạng lệch phân phối (distribution shift) theo thời gian mà một mạng nơ-ron huấn luyện một lần rồi giữ cố định trọng số khó thích nghi kịp. Để khắc phục, giải pháp cuối cùng được xây dựng theo kiến trúc **hybrid**, kết hợp hai thành phần bổ trợ cho nhau:

- Một thành phần thống kê cổ điển — **EWMA** (Exponentially Weighted Moving Average) — ước lượng xu hướng/nền hiện tại của chuỗi PM2.5 bằng trung bình có trọng số giảm dần theo cấp số nhân đối với các quan sát càng cũ càng ít quan trọng. Vì được tính trực tiếp từ dữ liệu chứ không qua huấn luyện bằng gradient, thành phần này có thể cập nhật gần như tức thời mỗi khi có thêm quan sát thật mới, bám theo sự thay đổi của nền nhanh hơn nhiều so với việc huấn luyện lại mạng nơ-ron.
- Mô hình **Direct GRU** (đã trình bày ở Mục 1.4) — không còn học trực tiếp PM2.5 tuyệt đối, mà học phần dao động ngắn hạn còn lại sau khi đã trừ đi thành phần xu hướng nói trên.

Toàn bộ các bước tiền xử lý và xây dựng mô hình trình bày dưới đây được thiết kế phục vụ trực tiếp cho kiến trúc hybrid này.



Hình 2.10: Kiến trúc hybrid: EWMA ước lượng Trend, GRU học Residual, cộng lại thành PM2.5 dự báo

Loại bỏ đặc trưng không liên quan

Dựa trên kết quả phân tích tương quan ở Mục 2.2 (Correlation Heatmap $|r| < 0.1$, và Cross-Correlation Function ở mọi độ trễ đều < 0.16), ba biến **Dust**, **UV Index**, **UV Index Clear Sky** được loại bỏ khỏi tập đặc trưng đầu vào nhằm giảm nhiễu và số chiều dữ liệu.

Gộp dữ liệu theo ngày

Các thử nghiệm ban đầu ở mức dữ liệu theo giờ cho thấy khi horizon dự báo được kéo dài (nhiều giờ đến nhiều ngày tới), sai số tăng nhanh và mô hình trở nên nhạy cảm

với nhiều ngắn hạn giữa các giờ liên tiếp. Vì vậy, toàn bộ dữ liệu (cả tập huấn luyện `cleaned_data.csv` lẫn tập dữ liệu mới dùng để đánh giá) được **gộp về mức trung bình ngày**. Phép gộp này làm mượt các dao động ngắn hạn trong ngày, đồng thời quy đổi horizon dự báo từ đơn vị giờ sang đơn vị ngày — giúp bài toán dự báo nhiều bước trở nên khả thi và ổn định hơn.

Tách xu hướng và phần dư (Decomposition)

Cụ thể, chuỗi PM2.5 theo ngày được **phân tách thành hai thành phần** trước khi đưa vào mô hình:

- **Xu hướng (Trend)**: ước lượng bằng EWMA nhân quả — chỉ sử dụng các quan sát trong quá khứ, với độ dài chu kỳ (span) = 7 ngày.
- **Phần dư (Residual)**: phần chênh lệch còn lại giữa giá trị PM2.5 thực tế và Xu hướng — phản ánh các dao động ngắn hạn quanh nền, có tính ổn định cao hơn nhiều so với chuỗi PM2.5 gốc.

Mô hình GRU được huấn luyện để học và dự báo trực tiếp **thành phần Residual** (thay cho PM2.5 tuyệt đối) ở cả đầu vào lẫn đầu ra. Khi tạo dự báo, giá trị PM2.5 cuối cùng được khôi phục bằng cách cộng Residual do mô hình dự báo với giá trị Xu hướng gần nhất đã biết.

Mã hóa chu kỳ thời gian

Vì đơn vị thời gian cơ sở giờ đây là ngày, đặc trưng lịch duy nhất còn phù hợp là **tháng** — được mã hóa dạng **cyclical encoding** bằng cặp hàm sin/cos nhằm phản ánh đúng tính chu kỳ (tháng 12 và tháng 1 về bản chất "gần nhau"):

$$\text{month_sin} = \sin\left(\frac{2\pi \cdot \text{month}}{12}\right), \quad \text{month_cos} = \cos\left(\frac{2\pi \cdot \text{month}}{12}\right) \quad (2.1)$$

Đặc trưng này giúp mô hình nắm bắt được tính mùa vụ của PM2.5 đã quan sát ở Mục 2.2 (nồng độ cao vào các tháng đầu năm, thấp vào mùa mưa giữa năm).

Chia tập Train / Validate / Test

Tập Test là một **bộ dữ liệu hoàn toàn mới**, thu thập ở giai đoạn sau đó — mô phỏng sát tình huống triển khai thực tế, khi mô hình phải dự báo cho dữ liệu chưa từng "nhìn thấy" trong suốt quá trình phát triển. Phần dữ liệu còn lại (gọi là **Pool**) được chia tiếp theo trình tự thời gian thành hai phần tách biệt hoàn toàn: **Train** (phần đầu, dùng để tạo các sequence huấn luyện) và **Validate** (300 ngày cuối của Pool, không chồng lấn với bất kỳ sequence huấn luyện nào) — dùng cho Grid Search và early-stopping bằng sliding-fold cross-validation (Mục 2.4.2). Việc tách Validate ra khỏi Train ngay từ đầu là điều kiện bắt buộc để validation loss thực sự phản ánh khả năng tổng quát hóa của mô hình, thay vì chỉ đo lại phần dữ liệu mô hình đã được học.

Bảng 2.2: Phân chia Train / Validate / Test (dữ liệu theo ngày)

Tập	Số ngày	Từ	Đến
Train	1.153	2022-08-04	2025-09-29
Validate	300	2025-09-30	2026-07-26
Test	28	2026-07-27	2026-08-23

Chuẩn hóa dữ liệu

Toàn bộ đặc trưng số (đã bao gồm thành phần Residual thay cho PM2.5 gốc) được chuẩn hóa về khoảng $[0, 1]$ bằng **MinMaxScaler**. Scaler chỉ được *fit* trên Pool, sau đó dùng để *transform* tập Test — nhằm tránh rò rỉ thông tin thống kê (min/max) của Test vào quá trình huấn luyện.

Tạo cặp (X, y) cho dự báo đa bước

Từ dữ liệu đã chuẩn hóa, các cặp (X, y) được tạo bằng kỹ thuật sliding window (Mục 1.1) với `window_size` = 28 ngày và `horizon` = 7 ngày. Độ dài cửa sổ quan sát này được xác định bằng thực nghiệm so sánh (7, 14 và 28 ngày, giữ nguyên toàn bộ phần còn lại của pipeline) — cửa sổ 28 ngày cho MAE và RMSE tổng hợp thấp nhất trên tập Test. Với mỗi vị trí i , X_i là ma trận gồm 28 bước thời gian $\times$ 9 đặc trưng (PM10, PM2.5 đã thay bằng Residual, Carbon Monoxide, Nitrogen Dioxide, Sulphur Dioxide, Ozone, Aerosol Optical Depth, `month_sin`, `month_cos`), còn y_i là một **vector 7 giá trị** — Residual của PM2.5 tại 7 ngày tiếp theo, được dự báo đồng thời trong một lượt duy nhất.

2.4 Xây dựng mô hình

Kiến trúc GRU: Direct Multi-output

Mô hình giữ nguyên khối GRU 2 lớp (dropout 0.2) đã trình bày ở Mục 1.4, nhưng lớp fully-connected cuối được đổi thành ánh xạ trạng thái ẩn tại bước thời gian cuối cùng thành **7 giá trị dự báo đồng thời** thay vì 1 giá trị — đúng chiến lược **Direct GRU** đã trình bày lý thuyết ở Mục 1.4. Lựa chọn này dựa trên cơ sở: bằng cách dự báo trọn horizon trong một lượt forward duy nhất, Direct GRU không dùng giá trị dự báo của chính nó làm đầu vào cho bước kế tiếp, nên tránh được hiện tượng **đồn sai số** (error compounding) — hạn chế cố hữu của chiến lược Recursive khi horizon tăng lên. Với 9 đặc trưng đầu vào và `hidden_size` = 32 (giá trị được chọn qua Grid Search ở mục kế tiếp), mô hình có tổng cộng **10.695 tham số có thể huấn luyện**.

Tinh chỉnh siêu tham số

Để việc chọn siêu tham số và early-stopping có một tín hiệu đánh giá đáng tin cậy nhưng vẫn tách biệt hoàn toàn khỏi dữ liệu huấn luyện, một cơ chế **sliding-fold cross-validation** được áp dụng riêng trên tập Validate (không dùng Train): tập Validate được quét bằng nhiều fold (X, y) liên tiếp, mỗi fold gồm 28 ngày làm đầu vào và 7 ngày kế tiếp làm mục tiêu, dịch đi đúng 7 ngày (bằng horizon) sau mỗi fold để phân mục tiêu giữa các fold không chồng lấn — thu được **38 fold**. Validation loss (MAE, thang chuẩn hóa) dùng

cho Grid Search và early-stopping được tính trung bình trên toàn bộ 38 fold này, thay vì dựa trên một khối dữ liệu cố định duy nhất — giúp tín hiệu đánh giá ổn định và đáng tin cậy hơn một khối 7 ngày đơn lẻ, đồng thời vẫn phản ánh đúng khả năng tổng quát hóa vì không chồng lấn với Train.

Grid Search được thực hiện trên không gian hai siêu tham số `hidden_size` $\in \{16, 32, 64\}$ và `learning_rate` $\in \{0.001, 0.0005\}$ (`window_size`= 28 ngày và `horizon`= 7 ngày giữ cố định) — mỗi cấu hình huấn luyện tối đa 20 epoch với early stopping (`patience`= 5).


Bảng 2.3: Kết quả Grid Search siêu tham số (val_loss trung bình trên 38 fold Validate, sắp xếp tăng dần)

hidden_size	learning_rate	val_loss (MAE, scaled)
32	0.0010	0.08452
32	0.0005	0.08492
64	0.0010	0.08517
64	0.0005	0.08532
16	0.0010	0.08543
16	0.0005	0.08690

Cấu hình được chọn là cấu hình có validation loss thấp nhất: `hidden_size`= 32, `learning_rate`= 0.001.

Huấn luyện mô hình cuối cùng

Với cấu hình đã chọn, mô hình được huấn luyện lại với ngân sách epoch lớn hơn (tối đa 40 epoch, `patience`= 8) để hội tụ đầy đủ hơn.



Hình 2.11: Learning curve — GRU Residual (`hidden_size`=32, `horizon`=7 ngày): toàn bộ quá trình (trái) và phóng to từ epoch 3 (phải), đường chấm xám đánh dấu epoch tốt nhất

Vì Validate lúc này là một tập tách biệt thật sự khỏi Train, đường Validation Loss ở Hình 2.11 thể hiện đúng một hành vi huấn luyện điển hình. Do hai epoch đầu tiên giảm rất mạnh (từ ≈ 0.41 xuống ≈ 0.10), panel bên trái tuy cho thấy toàn cảnh quá trình huấn luyện nhưng lại nén phần diễn biến sau đó vào một dải rất hẹp; panel bên phải (phóng to từ epoch 3) bộc lộ rõ diễn biến thật: Validation Loss tiếp tục giảm cùng nhịp với Train

Loss thêm vài epoch, đạt tốt nhất ≈ 0.0852 (thang chuẩn hóa) tại epoch 13, sau đó chững lại và dao động tăng nhẹ trong khi Train Loss vẫn tiếp tục giảm đều — dấu hiệu mô hình bắt đầu overfit lên tập Train. Cơ chế early stopping (patience= 8) phát hiện đúng xu hướng này và dừng huấn luyện ở epoch 21, khôi phục lại trọng số tốt nhất tại epoch 13.


2.5 Đánh giá mô hình: Walk-forward trên dữ liệu mới

Vì tập Test là dữ liệu thật hoàn toàn mới và mô hình dự báo trực tiếp trọn horizon 7 ngày trong một lượt, chiến lược **walk-forward theo từng khoảng thời gian** được áp dụng để tận dụng toàn bộ 28 ngày Test một cách công bằng và đáng tin cậy hơn một lượt dự báo duy nhất. Cụ thể, 28 ngày Test được chia thành **4 khoảng thời gian liên tiếp**, mỗi khoảng 7 ngày. Với khoảng thời gian đầu tiên, mô hình dự báo dựa trên 28 ngày lịch sử gần nhất đã biết (thuộc Pool). Sau khi giá trị thật của một khoảng thời gian được "quan sát", dữ liệu đó được dùng cho hai việc: (i) cập nhật cửa sổ lịch sử làm đầu vào cho khoảng thời gian kế tiếp, và (ii) **tinh chỉnh nhẹ** (fine-tune) lại trọng số mô hình — 5 epoch, với tốc độ học giảm 10 lần so với lúc huấn luyện ban đầu — nhằm giúp mô hình thích nghi phần nào với biến động mới quan sát được trước khi dự báo khoảng thời gian tiếp theo. Toàn bộ quá trình chỉ sử dụng giá trị thật đã biết làm đầu vào, không dùng lại dự báo của chính mô hình.

Kết quả dự báo theo từng khoảng thời gian

Bảng 2.4: Hiệu năng mô hình hybrid trên tập Test theo từng khoảng thời gian walk-forward


Khoảng	Thời gian	MAE ($\mu\text{g}/\text{m}^3$)	RMSE ($\mu\text{g}/\text{m}^3$)
1	2026-07-27 – 2026-08-02	2.735	3.624
2	2026-08-03 – 2026-08-09	4.273	5.106
3	2026-08-10 – 2026-08-16	1.817	2.184
4	2026-08-17 – 2026-08-23	2.312	2.556
Tổng hợp (28 ngày)		2.784	3.553



Hình 2.12: PM2.5: Thực tế và Dự báo walk-forward trên tập Test (đường chấm xám đánh dấu ranh giới giữa các khoảng thời gian)

Khoảng thời gian 2 (03/08 – 09/08) có sai số cao nhất trong 4 khoảng, trùng với giai đoạn PM2.5 thực tế sụt giảm mạnh nhất so với nền lịch sử mà mô hình đã học. Điều này cho thấy dù cơ chế Decomposition và fine-tune giữa các khoảng thời gian đã giúp cải thiện đáng kể so với việc dự báo trực tiếp trên PM2.5 tuyệt đối, mô hình vẫn cần một khoảng thời gian nhất định để thích nghi hoàn toàn với một biến động giảm đột ngột và kéo dài. Ở các khoảng thời gian sau (3 và 4), khi nền PM2.5 mới đã dần ổn định, sai số giảm trở lại xuống mức thấp hơn cả khoảng thời gian đầu tiên.

Phân tích Residual



Hình 2.13: Residual (Thực tế – Dự báo) trên tập Test, tổng hợp cả 4 khoảng thời gian walk-forward

Residual tổng hợp trên toàn bộ 28 ngày Test có **mean** = $-2.364 \mu\text{g}/\text{m}^3$ và **std** = $2.653 \mu\text{g}/\text{m}^3$ (Hình 2.13). Giá trị mean âm cho thấy mô hình vẫn còn thiên lệch (bias) hệ thống theo hướng dự báo cao hơn thực tế — hệ quả trực tiếp của việc nền PM2.5 trong giai đoạn Test thấp hơn đáng kể so với những gì mô hình quan sát được trong phần lớn dữ liệu huấn luyện. So với việc dự báo trực tiếp trên PM2.5 tuyệt đối (không qua Decomposition), độ lệch này đã được thu hẹp đáng kể, nhưng chưa được loại bỏ hoàn toàn — cho thấy đây là một hướng còn có thể cải thiện thêm.

2.6 Kết luận

Trong tiểu luận này, bài toán dự báo nồng độ PM2.5 theo chuỗi thời gian tại thành phố Quy Nhơn đã được xây dựng và đánh giá thông qua mô hình mạng GRU. Quy trình thực hiện đầy đủ các bước: làm sạch dữ liệu, phân tích khám phá chuyên biệt cho chuỗi thời gian (xu hướng, tính chu kỳ qua ACF/PACF/Decomposition), tiền xử lý và feature engineering, tinh chỉnh siêu tham số bằng Grid Search, và đánh giá mô hình trên dữ liệu thật hoàn toàn mới.

Điểm nổi bật của giải pháp cuối cùng là kiến trúc **hybrid**, kết hợp một thành phần thống kê cổ điển (Xu hướng EWMA, thích nghi tức thời với dữ liệu mới) với một mô hình GRU học phần dao động còn lại (Residual) — nhằm đối phó với hiện tượng lệch phân phối (distribution shift) theo thời gian mà một mô hình GRU thuần túy dự báo trực tiếp trên PM2.5 tuyệt đối không xử lý tốt. Kết hợp với chiến lược đánh giá walk-forward (cập nhật dữ liệu thật và tinh chỉnh nhẹ mô hình theo từng khoảng thời gian), giải pháp đạt **MAE** = $2.784 \mu\text{g}/\text{m}^3$ và **RMSE** = $3.553 \mu\text{g}/\text{m}^3$ trên trọn 28 ngày dữ liệu mới — cải thiện rõ rệt so với việc dự báo trực tiếp trên PM2.5 tuyệt đối không qua Decomposition.

Bên cạnh những kết quả tích cực, tiểu luận còn một số hạn chế: (1) dữ liệu chỉ trải dài khoảng 4 năm, giới hạn khả năng học đầy đủ chu kỳ năm mà EDA đã chỉ ra là chu kỳ chiếm ưu thế; (2) residual trên tập Test vẫn còn thiên lệch hệ thống (mean $\approx -2.36 \mu\text{g}/\text{m}^3$), cho thấy thành phần Xu hướng EWMA — dù thích nghi nhanh hơn nhiều so với việc huấn luyện lại mạng nơ-ron — vẫn chưa bám kịp hoàn toàn những biến động giảm đột ngột và kéo dài; (3) do tập dữ liệu mới chỉ có 28 ngày, việc đánh giá theo từng khoảng thời gian walk-forward tuy đáng tin cậy hơn một lượt dự báo duy nhất nhưng vẫn dựa trên số lượng mẫu còn khiêm tốn.

Hướng phát triển tiếp theo có thể tập trung vào: cải tiến thành phần Xu hướng (ví dụ các phương pháp trung bình trượt/làm mượt thích nghi khác, hoặc kết hợp nhiều thành phần theo chu kỳ khác nhau); mở rộng thời gian thu thập dữ liệu mới để việc đánh giá walk-forward có ý nghĩa thống kê vững chắc hơn; và thử nghiệm kiến trúc Seq2seq (Encoder–Decoder) đầy đủ — kiến trúc mà GRU vốn được thiết kế nguyên bản để giải quyết — cho phần Residual, thay cho Direct GRU hiện tại.

Tài liệu tham khảo

1. Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. *Dive into Deep Learning*. Cambridge University Press, 2023. <https://d2l.ai> — nguồn Hình 1.2 (Kiến trúc LSTM cell) và Hình 1.3 (Kiến trúc GRU).

(Danh sách tài liệu tham khảo sẽ được bổ sung thêm.)