



TRƯỜNG ĐẠI HỌC QUY NHƠN

TIỂU LUẬN HỌC PHẦN
HỌC MÁY VÀ KHAI PHÁ DỮ LIỆU

LOGISTIC REGRESSION VÀ
ỨNG DỤNG DỰ ĐOÁN KHẢ NĂNG
KHÁCH HÀNG ĐĂNG KÝ TIỀN GỬI
CÓ KỲ HẠN TẠI NGÂN HÀNG

Trình độ đào tạo:	Thạc sĩ
Học viên thực hiện:	Nguyễn Hồ Bảo Thiên
Lớp:	Khoa học dữ liệu K28B
Giảng viên hướng dẫn:	TS. Lê Xuân Vinh

Gia Lai, 2026

Mục lục

1	Giới thiệu	2
2	Thuật toán Logistic Regression	2
2.1	Mô hình toán học	2
2.2	Hàm sigmoid và ý nghĩa xác suất	3
2.3	Nguyên tắc phân loại	3
2.4	Hàm mất mát và quá trình huấn luyện	4
3	Phân tích dữ liệu	4
3.1	Mô tả dữ liệu	4
3.2	Phân tích, khám phá dữ liệu	5
3.2.1	Trực quan hóa dữ liệu cho các biến định lượng và các biến định tính	8
3.2.2	Phân tích khách hàng ở hai nhóm: Nhóm được liên hệ lần đầu tiên và nhóm đã được liên hệ ở chiến dịch marketing trước	12
3.2.3	Phân tích khách hàng theo nhóm tuổi	16
4	Tiền xử lý dữ liệu	18
4.1	Thay thế unknown ở hai cột job và education bằng mode	18
4.2	Thay thế unknown ở cột contact bằng K-Nearest Neighbors	20
4.3	Mã hóa và chuẩn hóa dữ liệu	20
5	Xây dựng mô hình	21
5.1	Baseline model	21
5.2	Cải thiện mô hình	22
5.3	So sánh và đánh giá	22
6	Kết luận	23

1 Giới thiệu

Trong bối cảnh các tổ chức tài chính ngày càng ứng dụng khoa học dữ liệu vào hoạt động kinh doanh, việc dự đoán hành vi khách hàng đóng vai trò quan trọng trong việc tối ưu chiến lược marketing. Một trong những bài toán phổ biến là dự đoán khả năng khách hàng đăng ký gửi tiền có kỳ hạn dựa trên thông tin cá nhân và lịch sử tương tác trước đó.

Trong báo cáo này, tôi thực hiện xây dựng mô hình Logistic Regression nhằm giải quyết bài toán phân loại nhị phân trên bộ dữ liệu Bank Marketing. Mục tiêu của bài toán là dự đoán biến mục tiêu (khách hàng có đăng ký gửi tiền hay không) dựa trên các đặc trưng như độ tuổi, nghề nghiệp, tình trạng hôn nhân, trình độ học vấn, phương thức liên hệ, số lần liên hệ trong chiến dịch, v.v.

Bộ dữ liệu Bank Marketing được thu thập từ các chiến dịch tiếp thị qua điện thoại của một ngân hàng tại Bồ Đào Nha trong giai đoạn từ năm 2008 đến 2013. Dữ liệu này được công bố phục vụ mục đích nghiên cứu và giảng dạy trong lĩnh vực khai phá dữ liệu và học máy. Các chiến dịch marketing được thực hiện thông qua hình thức gọi điện trực tiếp cho khách hàng để giới thiệu sản phẩm tiền gửi có kỳ hạn.

Thông qua bài tập này, em thực hành đầy đủ quy trình xây dựng mô hình học máy bao gồm:

- Phân tích khám phá dữ liệu (EDA)
- Tiền xử lý dữ liệu và xử lý giá trị thiếu
- Xử lý bài toán mất cân bằng dữ liệu
- Xây dựng mô hình phân loại
- Tối ưu siêu tham số và đánh giá mô hình

Báo cáo sẽ trình bày chi tiết từng bước thực hiện, phân tích kết quả thu được và đưa ra nhận xét về hiệu quả của các phương pháp đã áp dụng.

2 Thuật toán Logistic Regression

Logistic Regression là một thuật toán học máy thuộc nhóm mô hình phân loại tuyến tính, được sử dụng phổ biến trong các bài toán phân loại nhị phân. Mục tiêu của thuật toán là ước lượng xác suất một quan sát thuộc về lớp 1 dựa trên các đặc trưng đầu vào.

Khác với hồi quy tuyến tính (Linear Regression) dùng để dự đoán giá trị liên tục, Logistic Regression dự đoán xác suất và sau đó đưa ra quyết định phân loại dựa trên một ngưỡng xác định trước.

2.1 Mô hình toán học

Giả sử ta có vector đặc trưng đầu vào:

$$X = (x_1, x_2, \dots, x_n)$$

Mô hình Logistic Regression trước tiên xây dựng một tổ hợp tuyến tính của các đặc trưng:

$$z = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Trong đó:

- w_0 là hệ số chệch (bias)
- $w_1, w_2, \dots, w_n$ là các trọng số của từng đặc trưng

Giá trị z có thể nằm trong khoảng $(-\infty, +\infty)$. Để chuyển đổi z thành xác suất, mô hình sử dụng hàm sigmoid.

2.2 Hàm sigmoid và ý nghĩa xác suất

Hàm sigmoid được định nghĩa như sau:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Hàm này có các đặc điểm:

- Giá trị đầu ra nằm trong khoảng $(0,1)$
- Khi z rất lớn $\rightarrow \sigma(z)$ tiến gần 1
- Khi z rất nhỏ $\rightarrow \sigma(z)$ tiến gần 0

Do đó, xác suất một quan sát thuộc lớp 1 được tính như sau:

$$P(y = 1|X) = \frac{1}{1 + e^{-(w_0 + w_1x_1 + \dots + w_nx_n)}}$$

Trong bài toán Bank Marketing, giá trị này biểu diễn xác suất khách hàng đăng ký gửi tiền có kỳ hạn.

2.3 Nguyên tắc phân loại

Sau khi tính được xác suất $P(y = 1|X)$, mô hình sẽ đưa ra quyết định phân loại dựa trên một ngưỡng (threshold), thường được chọn là 0.5:

- Nếu $P(y = 1|X) \geq 0.5 \rightarrow$ dự đoán khách hàng đăng ký (lớp 1)
- Nếu $P(y = 1|X) < 0.5 \rightarrow$ dự đoán khách hàng không đăng ký (lớp 0)

Tuy nhiên, trong thực tế, ngưỡng này có thể điều chỉnh tùy theo mục tiêu bài toán, ví dụ như ưu tiên tăng Recall hoặc Precision.

2.4 Hàm mất mát và quá trình huấn luyện

Để tìm ra bộ trọng số tối ưu, Logistic Regression sử dụng hàm mất mát Log-Loss (còn gọi là Cross-Entropy Loss):

$$Loss = -[y \log(p) + (1 - y) \log(1 - p)]$$

Trong đó:

- y là giá trị thực tế (0 hoặc 1)
- p là xác suất dự đoán của mô hình

Quá trình huấn luyện sẽ tìm bộ tham số w sao cho tổng hàm mất mát trên toàn bộ tập dữ liệu là nhỏ nhất. Việc tối ưu thường được thực hiện bằng các phương pháp như Gradient Descent hoặc các biến thể của nó.

3 Phân tích dữ liệu

3.1 Mô tả dữ liệu

Bộ dữ liệu được sử dụng trong báo cáo này là Bank Marketing Dataset. Dữ liệu được thu thập từ các chiến dịch tiếp thị qua điện thoại của một ngân hàng tại Bồ Đào Nha trong giai đoạn 2008 - 2013. Mục tiêu của chiến dịch là thuyết phục khách hàng đăng ký gửi tiền có kỳ hạn.

Bộ dữ liệu đầy đủ gồm 45.211 quan sát (hàng) và 17 biến (cột), trong đó có 16 biến đầu vào và 1 biến mục tiêu. Mỗi hàng tương ứng với một khách hàng và một lần liên hệ trong chiến dịch marketing.

Các biến trong bộ dữ liệu bao gồm:

- **age**: Tuổi của khách hàng (biến số).
- **job**: Nghề nghiệp của khách hàng (biến phân loại).
- **marital**: Tình trạng hôn nhân (độc thân, đã kết hôn, ly hôn).
- **education**: Trình độ học vấn.
- **default**: Có đang nợ xấu hay không.
- **balance**: Số dư tài khoản trung bình trong năm, theo đơn vị là Euro (biến số).
- **housing**: Có vay để mua nhà hay không.
- **loan**: Có vay để chi tiêu cá nhân hay không.
- **contact**: Phương thức liên hệ (điện thoại di động, điện thoại bàn).
- **day**: Ngày liên hệ trong tháng.
- **month**: Tháng liên hệ.
- **duration**: Thời lượng cuộc gọi (tính bằng giây).

- **campaign**: Số lần liên hệ trong chiến dịch hiện tại.
- **pdays**: Số ngày kể từ lần liên hệ cuối cùng của chiến dịch tiếp thị trước đó (nếu có).
- **previous**: Số lần liên hệ trước chiến dịch hiện tại.
- **poutcome**: Kết quả của chiến dịch trước đó.
- **y**: Biến mục tiêu, cho biết khách hàng có đăng ký gửi tiền có kỳ hạn hay không (yes/no).

Trong phạm vi bài toán này, biến **y** sẽ được mã hóa thành 0 và 1 để phục vụ cho mô hình phân loại nhị phân. Dưới đây là năm dòng đầu tiên của bộ dữ liệu.

Bảng 1: Năm dòng dữ liệu đầu tiên của bộ dữ liệu Bank Marketing

age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
58	management	married	tertiary	no	2143	yes	no	unknown	5	may	261	1	-1	0	unknown	no
44	technician	single	secondary	no	29	yes	no	unknown	5	may	151	1	-1	0	unknown	no
33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
47	blue-collar	married	unknown	no	1506	yes	no	unknown	5	may	92	1	-1	0	unknown	no
33	unknown	single	unknown	no	1	no	no	unknown	5	may	198	1	-1	0	unknown	no

3.2 Phân tích, khám phá dữ liệu

Để có cái nhìn tổng quan về cấu trúc dữ liệu, hàm `info()` trong pandas được sử dụng nhằm kiểm tra số lượng quan sát, số lượng biến, kiểu dữ liệu của từng biến và số lượng giá trị không bị thiếu.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
#   Column          Non-Null Count  Dtype
---  -
0   age             45211 non-null  int64
1   job             45211 non-null  object
2   marital         45211 non-null  object
3   education       45211 non-null  object
4   default         45211 non-null  object
5   balance         45211 non-null  int64
6   housing         45211 non-null  object
7   loan           45211 non-null  object
8   contact         45211 non-null  object
9   day            45211 non-null  int64
10  month          45211 non-null  object
11  duration       45211 non-null  int64
12  campaign       45211 non-null  int64
13  pdays         45211 non-null  int64
14  previous       45211 non-null  int64
15  poutcome       45211 non-null  object
16  y              45211 non-null  object
```

dtypes: int64(7), object(10)
memory usage: 5.9+ MB

Kết quả cho thấy bộ dữ liệu gồm 45.211 quan sát và 17 biến. Trong đó:

- Có 7 biến kiểu số nguyên (**int64**), bao gồm: age, balance, day, duration, campaign, pdays và previous.
- Có 10 biến kiểu phân loại (**object**), bao gồm: job, marital, education, default, housing, loan, contact, month, poutcome và biến mục tiêu y.

Tất cả các biến đều có 45.211 giá trị non-null, cho thấy dữ liệu không có giá trị thiếu theo nghĩa truyền thống (NaN). Tuy nhiên, trong một số biến phân loại như job, education, contact và poutcome vẫn tồn tại giá trị *unknown*, điều này cần được xem xét xử lý trong bước tiền xử lý dữ liệu.

Từ kết quả trên có thể nhận thấy dữ liệu bao gồm cả biến định lượng và biến định tính, do đó cần thực hiện mã hóa các biến phân loại trước khi đưa vào mô hình học máy.

Tiếp theo, chúng ta có bảng thống kê mô tả cho các biến trong bộ dữ liệu, sử dụng hàm `describe()`. Đầu tiên là thống kê mô tả cho các biến định lượng.

Bảng 2: Thống kê mô tả các biến định lượng

	count	mean	std	min	25%	50%	75%	max
age	45211.0	40.936210	10.618762	18.0	33.0	39.0	48.0	95.0
balance	45211.0	1362.272058	3044.765829	-8019.0	72.0	448.0	1428.0	102127.0
day	45211.0	15.806419	8.322476	1.0	8.0	16.0	21.0	31.0
duration	45211.0	258.163080	257.527812	0.0	103.0	180.0	319.0	4918.0
campaign	45211.0	2.763841	3.098021	1.0	1.0	2.0	3.0	63.0
pdays	45211.0	40.197828	100.128746	-1.0	-1.0	-1.0	-1.0	871.0
previous	45211.0	0.580323	2.303441	0.0	0.0	0.0	0.0	275.0

Từ kết quả thống kê mô tả các biến định lượng, có thể rút ra một số điểm đáng chú ý như sau:

- **Biến age:** Tuổi trung bình của khách hàng khoảng 40.94, với độ lệch chuẩn 10.62. Khoảng tứ phân vị (Q1–Q3) từ 33 đến 48 tuổi cho thấy phần lớn khách hàng nằm trong nhóm tuổi trung niên. Giá trị nhỏ nhất là 18 và lớn nhất là 95.
- **Biến balance:** Số dư tài khoản trung bình khoảng 1362, tuy nhiên độ lệch chuẩn rất lớn (3044), cho thấy mức độ phân tán cao. Giá trị nhỏ nhất là -8019 và lớn nhất lên tới 102127. Điều này cho thấy biến balance có thể chứa nhiều giá trị ngoại lai (outliers).
- **Biến day:** Ngày liên hệ có giá trị trải đều từ 1 đến 31, trung bình khoảng 15.8, phù hợp với cấu trúc thời gian trong tháng và không có dấu hiệu bất thường rõ ràng.
- **Biến duration:** Thời lượng cuộc gọi trung bình khoảng 258 giây, với độ lệch chuẩn gần tương đương (257). Giá trị lớn nhất đạt 4918 giây cho thấy có những cuộc gọi rất dài, khả năng cao tồn tại ngoại lai trong biến này.
- **Biến campaign:** Số lần liên hệ trung bình trong chiến dịch là 2.76 lần, tuy nhiên có trường hợp lên đến 63 lần. Điều này cho thấy một số khách hàng bị liên hệ nhiều lần hơn mức thông thường.

- **Biến pdays:** Trung vị và các phân vị 25% và 75% đều bằng -1, cho thấy phần lớn khách hàng chưa từng được liên hệ trong chiến dịch trước đó.
- **Biến previous:** Giá trị trung bình là 0.58 và trung vị bằng 0, cho thấy đa số khách hàng chưa từng được liên hệ trước chiến dịch hiện tại. Giá trị lớn nhất là 275, phản ánh một số ít trường hợp có lịch sử liên hệ nhiều lần.

Nhìn chung, một số biến như balance, duration, campaign, previous và pdays có độ phân tán lớn và giá trị cực đại cao, cho thấy khả năng tồn tại ngoại lai rất lớn.

Sau đây là bảng thống kê mô tả cho các biến định tính.

Bảng 3: Thống kê mô tả các biến định tính

	count	unique	top	freq
job	45211	12	blue-collar	9732
marital	45211	3	married	27214
education	45211	4	secondary	23202
default	45211	2	no	44396
housing	45211	2	yes	25130
loan	45211	2	no	37967
contact	45211	3	cellular	29285
month	45211	12	may	13766
poutcome	45211	4	unknown	36959
y	45211	2	no	39922

Bảng thống kê mô tả các biến định tính cho thấy toàn bộ 45.211 quan sát đều đầy đủ dữ liệu (count = 45.211 cho tất cả các biến).

Cụ thể:

- **job:** Gồm 12 nhóm nghề nghiệp khác nhau, trong đó nhóm *blue-collar* (lao động chân tay) chiếm tỷ lệ cao nhất với 9.732 khách hàng.
- **marital:** Bao gồm 3 trạng thái hôn nhân, trong đó *married* (đã kết hôn) là phổ biến nhất với 27.214 trường hợp.
- **education:** Có 4 mức trình độ học vấn, phổ biến nhất là *secondary* (trình độ trung học) với 23.202 khách hàng.
- **default:** Phần lớn khách hàng không có nợ xấu ($no = 44.396$), cho thấy tỷ lệ khách hàng từng vỡ nợ là rất thấp.
- **housing:** Số lượng khách hàng có vay mua nhà có phần nhỉnh hơn so với những khách hàng không vay ($yes = 25.130$).
- **loan:** Phần lớn khách hàng không có vay tiêu dùng ($no = 37.967$).
- **contact:** Có 3 hình thức liên lạc, trong đó *cellular* (điện thoại di động) là phương thức phổ biến nhất với 29.285 trường hợp.
- **month:** Dữ liệu trải dài 12 tháng trong năm, trong đó tháng Năm (May) có số lượng liên hệ nhiều nhất (13.766).

- **poutcome**: Bao gồm 4 trạng thái kết quả chiến dịch trước đó, trong đó *unknown* chiếm tỷ lệ rất cao (36.959), cho thấy phần lớn khách hàng chưa từng được liên hệ hoặc không có thông tin về chiến dịch trước.
- **y** (biến mục tiêu): Phần lớn khách hàng không đăng ký tiền gửi có kỳ hạn ($no = 39.922$), cho thấy bộ dữ liệu có hiện tượng mất cân bằng lớp (class imbalance).

Bộ dữ liệu tuy không có các giá trị NaN nhưng lại tồn tại *unknown* ở các biến định tính. Do đó, ta tiến hành kiểm tra tỉ lệ *unknown* ở từng biến và thu được kết quả sau.

Bảng 4: Thống kê tỉ lệ xuất hiện của giá trị *unknown* ở các biến định tính


	Column name	Number of "unknown"	Percentage of "unknown" (%)
0	job	288	0.637013
2	education	1857	4.107407
6	contact	13020	28.798301
8	poutcome	36959	81.747805

Ta thấy rằng cột job và education xuất hiện *unknown* với tần suất tương đối thấp. Trong khi đó, *unknown* chiếm tỉ lệ xấp xỉ 29% trong cột contact. Riêng với cột poutcome, giá trị này dùng để xác định khách hàng chưa được liên hệ ở chiến dịch trước.


3.2.1 Trực quan hóa dữ liệu cho các biến định lượng và các biến định tính

Trực quan hóa dữ liệu là bước quan trọng trong quá trình phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA). Thông qua các biểu đồ và hình ảnh trực quan, ta có thể nhanh chóng nhận diện phân phối dữ liệu, xu hướng, sự mất cân bằng lớp cũng như các đặc điểm nổi bật của từng biến.

Trong phần này, các biến quan trọng của bộ dữ liệu sẽ được biểu diễn dưới dạng các biểu đồ khác nhau nhằm minh họa rõ hơn cấu trúc dữ liệu. Việc trực quan hóa không chỉ giúp hiểu sâu hơn về đặc điểm của tập dữ liệu mà còn hỗ trợ định hướng cho các bước tiền xử lý và xây dựng mô hình ở các phần tiếp theo. Đầu tiên ta đến với phân bố các giá trị ở cột mục tiêu - đã gặp hiện tượng mất cân bằng nghiêm trọng nêu trên.



(a) Biểu đồ cột




(b) Biểu đồ tròn


Hình 1: Phân bố biến mục tiêu

Số lượng khách hàng không đăng ký gửi tiền có kỳ hạn nhiều gấp gần 8 lần so với những người chọn đăng ký.


Một số biểu đồ cột cho các biến định tính được biểu diễn như sau.




(a) Job




(b) Education




(c) Marital



(d) Default




(e) Housing




(f) Loan

Hình 2: Trực quan hóa các biến định tính trong bộ dữ liệu bằng biểu đồ cột


Tiếp theo, ta trực quan hóa các biến định lượng bằng biểu đồ hộp. Biểu đồ hộp (Boxplot) là một phương pháp trực quan hóa dữ liệu được sử dụng để mô tả phân phối của một biến định lượng. Boxplot thể hiện năm giá trị quan trọng gồm: giá trị nhỏ nhất (minimum), tứ phân vị thứ nhất (Q1), trung vị (median), tứ phân vị thứ ba (Q3) và giá trị lớn nhất (maximum). Chức năng chính của Boxplot là giúp nhận diện nhanh mức độ phân tán, độ lệch phân phối và đặc biệt là phát hiện các giá trị ngoại lai (outliers).




(a) Age




(b) Balance




(c) Duration



(d) Campaign



(e) Pdays



(f) Previous

Hình 3: Trực quan hóa các biến định lượng trong bộ dữ liệu bằng biểu đồ hộp

Dựa trên các boxplot của các biến Age, Balance, Duration, Campaign, Pdays và Previous, có thể nhận thấy phần lớn các biến trong bộ dữ liệu đều có phân phối lệch phải với nhiều giá trị ngoại lai. Biến Age có phân phối tương đối tập trung trong khoảng 30–50 tuổi và chỉ xuất hiện một số ngoại lai ở nhóm tuổi cao, do đó mức độ lệch không quá nghiêm trọng. Ngược lại, Balance và Duration thể hiện độ lệch phải rất mạnh với đuôi phân phối dài và nhiều giá trị cực lớn so với phần lớn dữ liệu còn lại. Tương tự, Campaign cũng lệch phải khi đa số khách hàng chỉ được liên hệ vài lần nhưng tồn tại một số trường hợp được gọi rất nhiều lần. Biến Pdays có phân phối đặc biệt khi phần lớn giá trị tập trung ở giá trị -1 (chưa được liên hệ ở chiến dịch trước) và xuất hiện đuôi dài về phía phải, cho thấy sự chênh lệch lớn giữa các quan sát. Previous cũng tương tự khi phần lớn giá trị bằng 0 và chỉ một số ít trường hợp có giá trị cao. Nhìn chung, dữ liệu tồn tại nhiều ngoại lai và độ lệch lớn, điều này có thể ảnh hưởng đến các mô hình tuyến tính và cần áp dụng một số phương pháp chuẩn hóa phù hợp cho mô hình Logistic Regression.

3.2.2 Phân tích khách hàng ở hai nhóm: Nhóm được liên hệ lần đầu tiên và nhóm đã được liên hệ ở chiến dịch marketing trước

Ở phần này, đầu tiên ta tiến hành phân tích hành vi của các khách hàng đã được liên hệ ở chiến dịch trước, tức các khách hàng có biến poutcome nhận giá trị không phải là *unknown*.

Ta kiểm tra liệu bản ghi của các khách hàng đã được liên hệ ở chiến dịch trước có tồn tại *unknown* ở các cột hay không.

Bảng 5: Thống kê tỉ lệ *unknown* của các khách hàng đã được liên hệ ở chiến dịch trước

Column name	Number of "unknown"	Percentage of "unknown" (%)
0 job	31	0.483468
2 education	258	4.023706
6 contact	43	0.670618

Ta thấy rằng so với tổng thể bộ dữ liệu thì *unknown* của các khách hàng đã được liên hệ tồn tại với tần suất thấp hơn rất nhiều. Cột job và contact xuất hiện dưới mức 1% còn education là xấp xỉ 4%.


Tiếp đến, kiểm tra sự tương quan giữa phản hồi của khách hàng tại chiến dịch trước và chiến dịch hiện tại.

Bảng 6: Phân phối kết quả chiến dịch trước và chiến dịch hiện tại (biến mục tiêu)

poutcome	y	Count	Percentage (%)
failure	no	4283	66.80
success	yes	978	15.25
failure	yes	618	9.64
success	no	533	8.31

Từ bảng trên có thể thấy phần lớn khách hàng có kết quả chiến dịch trước là *failure* và không đăng ký tiền gửi trong chiến dịch hiện tại (66.80%). Tuy nhiên, trong nhóm khách hàng từng có kết quả *success*, tỷ lệ đăng ký (*yes*) cao hơn gần gấp đôi so với nhóm *failure*. Ngoài ra, ta cũng dễ dàng thấy được đa số khách hàng sẽ giữ nguyên quyết định giống với chiến dịch trước khi tổng tỉ lệ của *failure-no* và *success-yes* lên đến hơn 80%. Điều này cho thấy kết quả của chiến dịch trước có thể là một biến dự báo quan trọng đối với hành vi đăng ký ở hiện tại, tính riêng cho các khách hàng đã được liên hệ trước.

Ta tiến hành phân tích thêm về các đặc trưng khác nhằm hiểu rõ hơn về hai nguồn khách hàng.




Hình 4: Phân phối biến pdays theo biến poutcome (failure/success)

Boxplot của biến pdays theo biến poutcome cho thấy sự khác biệt đáng kể giữa hai nhóm *failure* và *success*. Nhóm *failure* có trung vị và khoảng tứ phân vị lớn hơn rõ rệt so với nhóm *success*, cho thấy thời gian kể từ lần liên hệ trước thường dài hơn ở các trường hợp thất bại. Ngược lại, nhóm *success* tập trung nhiều hơn ở các giá trị pdays thấp, phản ánh xu hướng khách hàng được liên hệ lại trong thời gian ngắn có xác suất thành công cao hơn. Cả hai nhóm đều xuất hiện nhiều giá trị ngoại lai ở phía phải với đuôi phân phối dài, tuy nhiên mức độ phân tán của nhóm *failure* lớn hơn.

Bảng 7: Thống kê mô tả biến duration theo biến poutcome


poutcome	min	max	mean	median	std
failure	5	2219	244.19	177.0	227.13
success	1	2062	316.87	253.0	236.86

Bảng thống kê mô tả cho thấy biến duration có sự khác biệt rõ rệt giữa hai nhóm *failure* và *success*. Cụ thể, nhóm *success* có giá trị trung bình 316.87 và trung vị 253.0 cao hơn đáng kể so với nhóm *failure* (mean = 244.19, median = 177.0), cho thấy các cuộc gọi dẫn đến thành công thường có thời lượng dài hơn.



Hình 5: Phân phối biến duration theo biến poutcome (failure/success)


Ngoài ra khi chia khách hàng thành hai nhóm: nhóm có thời gian gọi trên mức trung bình và nhóm ở dưới mức trung bình thì sự khác biệt cũng được thể hiện khá rõ nét.



Hình 6: Phân phối của thời lượng cuộc gọi trên/dưới mức trung bình theo biến mục tiêu


Biểu đồ cho thấy mối quan hệ rõ rệt giữa thời lượng cuộc gọi và kết quả đăng ký (y). Trong nhóm các cuộc gọi có thời lượng dưới mức trung bình, số lượng khách hàng không đăng ký (3563) vượt trội so với số khách hàng đăng ký (624). Ngược lại, trong nhóm có thời lượng trên trung bình, số khách hàng đăng ký (972) chiếm tỷ lệ cao hơn đáng kể so với nhóm dưới trung bình. Điều này cho thấy khi thời lượng cuộc gọi tăng lên, xác suất khách hàng chấp nhận đăng ký có xu hướng tăng theo. Do đó, duration có thể được xem là một biến dự báo quan trọng và có sức phân biệt mạnh đối với biến mục tiêu.

Biểu đồ tròn dưới đây cho ta thấy rõ hơn tỉ lệ phần trăm của hai nhóm khách hàng trên.



Hình 7: Tỉ lệ phần trăm của hai nhóm khách hàng có thời gian gọi trên/dưới mức trung bình theo biến mục tiêu

Ngoài biến duration, biến housing cũng cho ta thấy sự khác biệt tương đối rõ ràng.



Hình 8: Phân phối của biến housing (vay mua nhà) theo biến mục tiêu

Biểu đồ thể hiện mối quan hệ giữa biến vay mua nhà và kết quả đăng ký tiền gửi có kỳ hạn. Có thể thấy trong nhóm khách hàng không đăng ký, số người đang có khoản vay mua nhà (3404) cao hơn đáng kể so với nhóm không có vay (1412). Ngược lại, trong nhóm đăng ký thành công, số khách hàng không có khoản vay mua nhà (1059) cao gần gấp đôi so với nhóm có vay (537). Kết quả gợi ý rằng tình trạng vay mua nhà có thể có sức ảnh hưởng nhất định đến quyết định tham gia đăng ký tiền gửi và là một biến có giá trị trong mô hình dự đoán.

Bảng 8: Thống kê mô tả biến balance theo biến mục tiêu y

y	min	max	mean	median	std
no	-1884	37378	1464.67	554.5	2678.46
yes	-556	81204	1917.53	864.5	3701.98

Bảng thống kê cho thấy sự khác biệt đáng kể về số dư tài khoản giữa hai nhóm khách hàng. Nhóm đăng ký thành công có giá trị trung bình (1917.53) và trung vị (864.5) cao hơn rõ rệt so với nhóm không đăng ký, mean = 1464.67; median = 554.5). Điều này cho thấy khách hàng có số dư cao hơn có xu hướng chấp nhận sản phẩm nhiều hơn. Độ lệch chuẩn của cả hai nhóm đều lớn, đặc biệt ở nhóm *yes*, phản ánh sự phân tán mạnh và sự tồn tại của các giá trị cực đại rất lớn (max = 81204). Ngoài ra, giá trị tối thiểu âm ở cả hai nhóm cho thấy tồn tại các trường hợp thấu chi.

Tiếp đến, ta tiến hành phân tích đặc trưng và hành vi của các khách hàng lần đầu được liên hệ ở chiến dịch này, tức biến *poutcome* nhận giá trị *unknown*.

Bảng 9: Phân bố biến mục tiêu y trong nhóm *poutcome = unknown*

y	Count	Percentage
no	33520	90.83%
yes	3385	9.17%

Bảng 10: Tần suất kết hợp giữa *previous* và *pdays*

previous	pdays	count
0	-1	36900
1	98	1
2	188	1
2	416	1
5	168	1
7	528	1

Hai bảng thống kê cho thấy những đặc điểm rất đáng chú ý của dữ liệu. Đối với bảng phân bố biến mục tiêu trong nhóm *poutcome* = *unknown*, có thể thấy tỷ lệ khách hàng không đăng ký chiếm ưu thế tuyệt đối với 90.83%, gấp 10 lần so với nhóm đăng ký thành công - chỉ chiếm 9.17%. Điều này phản ánh sự mất cân bằng lớp (class imbalance) khá rõ rệt và cho thấy khả năng khách hàng đăng ký là tương đối thấp khi họ được tiếp cận lần đầu tiên.

Ở bảng tần suất kết hợp giữa *previous* và *pdays*, phần lớn quan sát tập trung tại trường hợp *previous* = 0 và *pdays* = -1 với số lượng 36900, cho thấy đa số khách hàng chưa từng được liên hệ trước đó. Các tổ hợp còn lại xuất hiện với tần suất rất nhỏ, tổng chỉ có 5 trường hợp. Ta có thể xem 5 trường hợp này là ngoại lai và bỏ qua chúng khi xây dựng mô hình.

Tiếp theo, ta so sánh thời lượng cuộc gọi (*duration*) của nhóm khách hàng được liên hệ lần đầu với nhóm đã được liên hệ ở chiến dịch marketing trước.


Bảng 11: Thống kê mô tả biến *duration* theo *poutcome*

poutcome	min	max	mean	median
failure	5	2219	244.19	177.0
other	4	2053	255.72	182.5
success	1	2062	316.87	253.0
unknown	0	4918	257.81	177.0


So sánh giữa các nhóm cho thấy *duration* ở nhóm *poutcome* = *unknown* có giá trị trung bình (257.81) cao hơn nhóm *failure* (244.19), xấp xỉ nhóm *other* (255.72), nhưng thấp hơn đáng kể so với nhóm *success* (316.87). Về trung vị, nhóm *unknown* (177.0) tương đương với *failure* (177.0), thấp hơn không quá nhiều so với *other* (182.5) và cả ba nhóm cũng thấp hơn rất nhiều so với *success* (253.0). Ngoài ra, giá trị lớn nhất của nhóm *unknown* (4918) vượt trội so với các nhóm còn lại, cho thấy tồn tại một số cuộc gọi có thời lượng rất lớn trong nhóm này, cho thấy khả năng tồn tại ngoại lai là rất cao. Nhìn chung, xét về xu hướng, *duration* của nhóm *unknown* gần với nhóm thất bại hơn là nhóm thành công, tuy nhiên sự xuất hiện của các giá trị cực đại lớn làm tăng nhẹ giá trị trung bình của nhóm này.

3.2.3 Phân tích khách hàng theo nhóm tuổi

Ở phần này, ta chia phân khúc khách hàng thành các nhóm tuổi như sau: U30, 30-40, 40-50, 50-60, 60-70, 70-80 và 80+.



Hình 9: Tỷ lệ vay mua nhà theo nhóm tuổi



Hình 10: Trung bình số dư tài khoản theo nhóm tuổi

Hai biểu đồ cho thấy mối quan hệ giữa độ tuổi, tình trạng vay mua nhà và mức số dư trung bình.

Ở các biểu đồ tròn, tỷ lệ khách hàng có vay mua nhà cao nhất tập trung ở các nhóm tuổi dưới 50, đặc biệt nhóm 30–40 (62.8%) và 40–50 (58.4%). Nhóm dưới 30 tuổi cũng có tỷ lệ vay tương đối cao (57.6%). Tuy nhiên, từ nhóm 50–60, tỷ lệ vay giảm xuống (43.9%) và giảm mạnh ở các nhóm lớn tuổi hơn như 60–70 (20.7%), 70–80 (2.8%) và gần như bằng 0 ở nhóm trên 80 tuổi. Điều này cho thấy nhu cầu hoặc khả năng vay mua nhà tập trung chủ yếu ở nhóm tuổi lao động trung niên và giảm đáng kể khi tuổi tăng cao.

Ở biểu đồ cột, số dư trung bình có xu hướng tăng dần theo độ tuổi. Nhóm dưới 30 có mức số dư thấp nhất và tăng đều qua các nhóm tuổi, đạt mức cao nhất ở nhóm 80+. Như vậy có thể thấy rằng các khách hàng lớn tuổi có xu hướng sở hữu số dư tài khoản

cao hơn, họ lại ít có nhu cầu vay mua nhà hơn so với các nhóm tuổi trẻ hơn.

Tổng hợp hai biểu đồ cho thấy tồn tại mối quan hệ ngược chiều giữa mức số dư và tình trạng vay mua nhà theo độ tuổi: nhóm trẻ và trung niên có số dư trung bình thấp hơn và đây có thể là lí do họ có xu hướng vay mua nhà nhiều hơn, trong khi nhóm lớn tuổi có số dư cao nhưng hầu như không vay.

4 Tiền xử lý dữ liệu

Ở bước tiền xử lý dữ liệu, ta sẽ loại bỏ các khách hàng đã được liên hệ trước đó nhưng poutcome = *unknown*, chỉ có 5 trường hợp được ghi nhận như vậy, chiếm tỷ lệ rất nhỏ nên có thể bỏ qua. Phần tiền xử lý chủ yếu tập trung vào việc thay các giá trị *unknown* ở các cột job, education và contact bằng các phương pháp khác nhau.

Cần lưu ý rằng việc thay thế các giá trị *unknown* phải được thực hiện sau khi chia tập dữ liệu thành tập huấn luyện (train) và tập kiểm tra (test), trong đó giá trị mode chỉ được tính trên tập huấn luyện nhằm tránh hiện tượng rò rỉ dữ liệu (data leakage) và đảm bảo tính khách quan của quá trình đánh giá mô hình.

4.1 Thay thế unknown ở hai cột job và education bằng mode

Bảng 12: Trình độ học vấn phổ biến nhất theo từng nhóm nghề nghiệp

Job	Most Frequent Education	Percentage (%)
housemaid	primary	48.96
services	secondary	83.45
admin.	secondary	81.59
technician	secondary	68.20
unemployed	secondary	57.43
blue-collar	secondary	54.90
student	secondary	54.83
retired	secondary	43.08
management	tertiary	82.29
self-employed	tertiary	52.08
entrepreneur	tertiary	47.39

Bảng 13: Nghề nghiệp phổ biến nhất theo từng trình độ học vấn

Education	Most Frequent Job	Percentage (%)
primary	blue-collar	55.11
secondary	blue-collar	23.72
tertiary	management	59.04

Trong hai bảng trên, các giá trị tiếng Anh đã được sử dụng trong bộ dữ liệu gốc được diễn giải như sau:

- **Trình độ học vấn (Education):**

- *primary*: Tiểu học

- *secondary*: Trung học
- *tertiary*: Đại học trở lên

• **Nghề nghiệp (Job):**

- *housemaid*: Giúp việc gia đình
- *services*: Nhân viên dịch vụ
- *admin*: Nhân viên hành chính
- *technician*: Kỹ thuật viên
- *unemployed*: Thất nghiệp
- *blue-collar*: Lao động phổ thông (lao động tay chân)
- *student*: Sinh viên
- *retired*: Nghỉ hưu
- *management*: Quản lý
- *self-employed*: Tự kinh doanh/Tự làm chủ
- *entrepreneur*: Doanh nhân

Bảng 12 trình bày trình độ học vấn phổ biến nhất trong từng nhóm nghề nghiệp, trong khi Bảng 13 thể hiện nghề nghiệp phổ biến nhất tương ứng với từng nhóm trình độ học vấn. Việc phân tích đồng thời hai bảng cho phép đánh giá mối liên hệ hai chiều giữa hai biến phân loại này.

Từ bảng 12 có thể nhận thấy rằng trình độ *secondary* chiếm ưu thế ở phần lớn các nhóm nghề nghiệp, bao gồm *services* (83.45%), *admin* (81.59%), *technician* (68.20%), *unemployed* (57.43%), *blue-collar* (54.90%), *student* (54.83%) và *retired* (43.08%). Điều này cho thấy trình độ trung học là mức học vấn phổ biến nhất trong mẫu nghiên cứu. Trong khi đó ở nhóm trình độ *tertiary*, tỷ lệ cao tập trung chủ yếu ở các nghề mang tính chuyên môn hoặc quản lý như *management* (82.29%), *self-employed* (52.08%) và *entrepreneur* (47.39%). Kết quả này có tính thuyết phục tương đối cao khi các vị trí quản lý và điều hành thường yêu cầu trình độ học vấn cao hơn. Ngược lại, nhóm *primary* xuất hiện nổi bật nhất ở nghề *housemaid* với tỷ lệ 48.96%.

Khi phân tích theo chiều ngược lại (Bảng 13), có thể quan sát rằng đối với nhóm *primary*, nghề phổ biến nhất là *blue-collar* (55.11%), phản ánh xu hướng người có trình độ học vấn thấp tập trung vào các công việc lao động tay chân. Đối với nhóm *secondary*, nghề phổ biến nhất vẫn là *blue-collar* (23.72%), cho thấy đây là nhóm nghề có quy mô lớn trong bộ dữ liệu. Trong khi đó, ở nhóm *tertiary*, nghề phổ biến nhất là *management* (59.04%), khẳng định mối liên hệ mạnh giữa trình độ học vấn cao và vị trí quản lý.

Tổng hợp hai bảng cho thấy tồn tại mối quan hệ đáng kể giữa nghề nghiệp và trình độ học vấn; hai biến này không độc lập với nhau. Dữ liệu phản ánh rõ sự phân tầng xã hội theo học vấn: trình độ thấp gắn với lao động phổ thông, trình độ trung học phân bố rộng trong nhiều ngành nghề, và trình độ đại học trở lên tập trung nhiều ở nhóm quản lý và điều hành.

Dựa trên mối quan hệ chặt chẽ giữa nghề nghiệp và trình độ học vấn đã được phân tích ở trên, các giá trị *unknown* được xử lý bằng phương pháp thay thế theo giá trị xuất hiện nhiều nhất (mode) có điều kiện: cụ thể, giá trị *unknown* của biến job được thay thế

dựa trên nghề phổ biến nhất trong cùng nhóm trình độ học vấn, và ngược lại, giá trị thiếu của biến *education* được thay bằng trình độ phổ biến nhất trong cùng nhóm nghề nghiệp. Cách tiếp cận này giúp duy trì tính nhất quán giữa hai biến và hạn chế sai lệch so với việc thay thế bằng mode toàn cục.

4.2 Thay thế unknown ở cột contact bằng K-Nearest Neighbors

Bên cạnh phương pháp thay thế theo giá trị xuất hiện nhiều nhất, thuật toán K-Nearest Neighbors (KNN) cũng được sử dụng như một phương pháp nội suy dữ liệu khuyết, trong đó giá trị *unknown* của một quan sát được ước lượng dựa trên K quan sát tương đồng nhất trong không gian đặc trưng. Với riêng biến *contact* (phương thức liên lạc), các giá trị *unknown* sẽ được thay thế dựa trên các biến *duration* (thời lượng cuộc gọi), *age* (tuổi), *campaign* (Số lần liên hệ trong chiến dịch hiện tại) và *previous* (Số lần liên hệ trước chiến dịch hiện tại).

Bảng 14: Phân bố biến *contact*

contact	count
cellular	20539
unknown	9020
telephone	1996

Từ bảng trên có thể nhận thấy phương thức liên lạc qua *cellular* chiếm tỷ trọng lớn nhất (20.539), vượt trội so với *telephone* (1.996). Tuy nhiên, số lượng giá trị *unknown* còn khá cao (9.020).

Sau khi áp dụng phương pháp KNN, ta có phân bố biến *contact* mới như sau.

Bảng 15: Phân bố biến *contact* sau khi thay thế unknown

contact	count
cellular	29405
telephone	2150

4.3 Mã hóa và chuẩn hóa dữ liệu

Do các mô hình học máy không thể xử lý trực tiếp các đặc trưng định tính, việc mã hóa các biến này thành dạng số là bước tiền xử lý cần thiết nhằm đảm bảo dữ liệu phù hợp với yêu cầu tính toán của mô hình. Ngoài ra, các biến định lượng cũng được chuẩn hóa nhằm đưa dữ liệu về cùng một thang đo, giúp tránh hiện tượng một số biến có độ lớn vượt trội chi phối quá trình huấn luyện mô hình.

Ta loại bỏ hai cột *day* và *month* (chỉ ngày tháng khách hàng được liên hệ), các cột còn lại được mã hóa và chuẩn hóa như sau.

- **Binary encoding:** Áp dụng cho các biến *housing*, *default*, *loan* cũng như biến mục tiêu với ánh xạ $no \rightarrow 0$ và $yes \rightarrow 1$.
- **Binary encoding cho phương thức liên lạc:** Biến *contact* được mã hóa với $telephone \rightarrow 0$, $cellular \rightarrow 1$.

- **Ordinal encoding cho trình độ học vấn:** Biến *education* được mã hóa có thứ tự *primary* $\rightarrow 0$, *secondary* $\rightarrow 1$, *tertiary* $\rightarrow 2$.
- **Ordinal encoding cho nhóm tuổi:** Biến *age_group* được mã hóa theo thứ tự tăng dần của độ tuổi từ *U30* đến *80+*.
- **One-Hot Encoding:** Áp dụng cho các biến *marital*, *poutcome*, *job*.
- **Chuẩn hóa (Standard Scaler):** Áp dụng cho các biến số *age*, *balance*, *campaign*, *pdays*, *previous*, *duration* nhằm đưa dữ liệu về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1.

5 Xây dựng mô hình

5.1 Baseline model

Bảng 16: Hiệu năng mô hình baseline Logistic Regression

Class	Precision	Recall	F1-score	Support
0	0.92	0.98	0.95	11962
1	0.64	0.31	0.41	1562
Macro Avg	0.78	0.64	0.68	13524
Weighted Avg	0.88	0.90	0.88	13524
Accuracy	0.8997			
ROC-AUC	0.8808			

Bảng 17: Confusion matrix của mô hình baseline Logistic Regression

	Predicted 0	Predicted 1
Actual 0	11687	275
Actual 1	1082	480

Bảng trên cho thấy mô hình Logistic Regression ở mức cơ sở (baseline) đạt **Accuracy = 0.8997** và **ROC-AUC = 0.8808**, cho thấy khả năng phân biệt tổng thể giữa hai lớp là tương đối tốt. Tuy nhiên, khi phân tích chi tiết theo từng lớp, có thể nhận thấy sự mất cân bằng rõ rệt trong hiệu năng dự đoán.

Cụ thể, đối với lớp 0 (khách hàng không đăng ký), mô hình đạt **Recall = 0.98** và **F1-score = 0.95**, cho thấy khả năng nhận diện lớp đa số rất cao. Ngược lại, đối với lớp 1 (khách hàng đăng ký), **Recall chỉ đạt 0.31**, đồng nghĩa với việc mô hình bỏ sót một lượng lớn khách hàng tiềm năng (1082 trường hợp False Negative). Mặc dù Precision của lớp 1 đạt 0.64, giá trị F1-score chỉ ở mức 0.41, phản ánh sự suy giảm hiệu năng đáng kể đối với lớp thiểu số.

Sự chênh lệch giữa *Macro Average* (F1 = 0.68) và *Weighted Average* (F1 = 0.88) cho thấy ảnh hưởng của hiện tượng mất cân bằng dữ liệu. Giá trị Accuracy cao chủ yếu đến từ việc mô hình dự đoán tốt lớp chiếm đa số, trong khi hiệu suất trên lớp thiểu số còn

hạn chế. Do đó, kết quả baseline này đặt ra nhu cầu cải thiện mô hình nhằm nâng cao khả năng nhận diện lớp thiểu số.

5.2 Cải thiện mô hình

Ở phần cải thiện, tôi sử dụng hai phương pháp đó là **SMOTE (Synthetic Minority Over-sampling Technique)** và **GridSearchCV**.

- **SMOTE** được áp dụng để xử lý vấn đề mất cân bằng lớp bằng cách tạo thêm các mẫu tổng hợp cho lớp thiểu số, từ đó giúp mô hình học được ranh giới phân lớp rõ ràng hơn.
- **GridSearch** kết hợp **Cross-Validation** để thực hiện quá trình tinh chỉnh siêu tham số (hyperparameter tuning). Phương pháp này cho phép tìm kiếm hệ thống các tổ hợp tham số tối ưu, qua đó cải thiện hiệu suất mô hình một cách khách quan và ổn định.

Sự kết hợp giữa xử lý mất cân bằng dữ liệu và tối ưu siêu tham số được kỳ vọng sẽ giúp mô hình đạt được kết quả tốt hơn so với baseline ban đầu.

Bảng 18: Hiệu năng mô hình sau khi áp dụng SMOTE và GridSearch

Class	Precision	Recall	F1-score	Support
0	0.95	0.92	0.93	11962
1	0.49	0.61	0.54	1562
Macro Avg	0.72	0.76	0.74	13524
Weighted Avg	0.89	0.88	0.89	13524
Accuracy		0.8800		
ROC-AUC		0.8804		

Bảng 19: Confusion Matrix sau khi áp dụng SMOTE và GridSearch

	Predicted 0	Predicted 1
Actual 0	10957	1005
Actual 1	614	948

5.3 So sánh và đánh giá

Dựa trên kết quả ở Bảng 16–19, có thể nhận thấy việc áp dụng SMOTE kết hợp với GridSearch đã tạo ra những thay đổi đáng kể trong hiệu năng mô hình.

Trước hết, xét về **Accuracy** và **ROC-AUC**, hai mô hình gần như tương đương nhau (Accuracy giảm nhẹ từ 0.8997 xuống 0.8800, ROC-AUC xấp xỉ 0.88). Điều này cho thấy khả năng phân biệt tổng thể giữa hai lớp không thay đổi nhiều sau khi cải thiện mô hình.

Tuy nhiên, sự khác biệt quan trọng nằm ở hiệu năng dự đoán lớp thiểu số (Class 1). Ở mô hình baseline, Recall của lớp 1 chỉ đạt 0.31, cho thấy mô hình bỏ sót nhiều trường hợp dương tính thực sự (1082 mẫu bị phân loại sai). Sau khi áp dụng SMOTE và tối ưu siêu tham số, Recall của lớp 1 tăng đáng kể lên 0.61, đồng thời số lượng False Negative

giảm mạnh (từ 1082 xuống còn 614). Điều này chứng tỏ mô hình đã cải thiện đáng kể khả năng phát hiện khách hàng thuộc lớp mục tiêu.

Mặc dù Precision của lớp 1 giảm từ 0.64 xuống 0.49 do số lượng False Positive tăng (từ 275 lên 1005), sự đánh đổi này là hợp lý trong bối cảnh dữ liệu mất cân bằng, đặc biệt khi mục tiêu bài toán ưu tiên phát hiện đúng lớp thiểu số hơn là tối thiểu hóa cảnh báo sai.

Bên cạnh đó, F1-score của lớp 1 tăng từ 0.41 lên 0.54, phản ánh sự cải thiện cân bằng giữa Precision và Recall. Macro Average cũng tăng từ 0.68 lên 0.74, cho thấy hiệu năng giữa các lớp trở nên cân bằng hơn.

Tóm lại, việc áp dụng SMOTE và GridSearch không làm tăng đáng kể độ chính xác tổng thể, nhưng đã cải thiện rõ rệt khả năng dự đoán lớp thiểu số – yếu tố quan trọng trong các bài toán dữ liệu mất cân bằng như Bank Marketing. Do đó, mô hình cải tiến được đánh giá là phù hợp và hiệu quả hơn so với mô hình baseline.

6 Kết luận

Trong bài tiểu luận này, bài toán phân loại khách hàng đăng ký tiền gửi có kỳ hạn trong bộ dữ liệu Bank Marketing được xây dựng và đánh giá thông qua mô hình Logistic Regression. Kết quả từ mô hình baseline cho thấy độ chính xác tổng thể tương đối cao; tuy nhiên, hiệu năng dự đoán lớp thiểu số (khách hàng đăng ký) còn hạn chế, đặc biệt là Recall thấp, phản ánh tình trạng bỏ sót nhiều khách hàng tiềm năng.

Để khắc phục vấn đề mất cân bằng dữ liệu, kỹ thuật SMOTE được áp dụng nhằm tăng cường số lượng mẫu của lớp thiểu số, đồng thời GridSearch kết hợp Cross-Validation được sử dụng để tối ưu hóa siêu tham số. Kết quả thực nghiệm cho thấy mặc dù Accuracy và ROC-AUC không thay đổi đáng kể, nhưng Recall và F1-score của lớp thiểu số đã được cải thiện rõ rệt. Số lượng trường hợp dự đoán sai âm (False Negative) giảm mạnh, chứng tỏ mô hình cải tiến có khả năng phát hiện khách hàng mục tiêu tốt hơn.

Mặc dù Precision của lớp thiểu số có giảm do sự gia tăng False Positive, sự đánh đổi này là hợp lý trong bối cảnh bài toán marketing, nơi việc nhận diện đúng khách hàng tiềm năng thường quan trọng hơn việc hạn chế hoàn toàn các cảnh báo sai.

Tổng thể, mô hình sau khi áp dụng SMOTE và GridSearch được đánh giá là phù hợp hơn cho bài toán phân loại trong môi trường dữ liệu mất cân bằng. Kết quả nghiên cứu khẳng định rằng việc kết hợp kỹ thuật cân bằng dữ liệu và tối ưu siêu tham số đóng vai trò quan trọng trong việc nâng cao hiệu năng mô hình phân loại thực tế.

Tài liệu tham khảo

- [1] Lê Xuân Vinh, Giáo trình Trí tuệ nhân tạo - Học máy, Tài liệu lưu hành nội bộ (2023).
- [2] Vũ Hữu Tiệp, Machine Learning cơ bản, Website: <https://machinelearningcoban.com/> (2017).
- [3] Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. Journal of artificial intelligence research, 16, 321-357.
- [4] Moro, S., Cortez, P., Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22-31.
- [5] Kaiser, J. (2014). Dealing with Missing Values in Data. Journal Of Systems Integration (1804-2724), 5(1).